

Padrões Alimentares de Perfis Depressivos no Brasil: Uma Caracterização Usando Aprendizado de Máquina

Luan Inaibes

Dezembro 2025

Introdução

A depressão é um transtorno mental caracterizado por tristeza persistente, perda de interesse, alterações no apetite e no sono, fadiga e sentimentos de desamparo, reduzindo substancialmente a qualidade de vida. No contexto brasileiro, o aumento dessa condição tem imposto desafios tanto à saúde pública quanto às dinâmicas socioeconômicas.

A depressão constitui um dos transtornos mentais mais prevalentes e incapacitantes, marcada por um conjunto de sintomas emocionais, cognitivos e comportamentais que comprometem o bem-estar e o funcionamento cotidiano dos indivíduos. No Brasil, sua incidência crescente demanda investigações que ultrapassem dimensões exclusivamente biológicas e incluam fatores comportamentais e ambientais, entre os quais se destaca a alimentação.

Evidências científicas sugerem que padrões alimentares têm impacto significativo tanto no risco quanto na gravidade de sintomas depressivos. Dietas baseadas em alimentos ultraprocessados e pobres em micronutrientes essenciais tendem a estar associadas à piora do quadro, enquanto padrões alimentares ricos em alimentos in natura, compostos bioativos e ácidos graxos ômega-3 parecem exercer efeitos protetores (Chen & Cao; Hosseinzadeh & Vafa; Fan & Zhao; Cheng & Chu; Gadelha de Araújo).

O objetivo central desta investigação é descrever e classificar os hábitos alimentares de indivíduos diagnosticados com transtorno depressivo no Brasil, identificando em que

medida esses padrões incluem alimentos com potencial efeito protetor ou de risco para a depressão. Para isso, empregam-se modelos de *machine learning*, com destaque para algoritmos como árvores de decisão e florestas aleatórias.

A organização metodológica deste estudo baseou-se no método CAPTO, conforme proposta por Zarate. De maneira adaptada ao cenário atual, o procedimento seguiu as seguintes etapas:

1. Socialização: formação de grupos de trabalho, e identificação de dimensões e aspectos;
2. Mapeamento: explicitação do conhecimento tácito;
3. Combinação: troca de experiências, e combinação dos modelos/mapas explicitados;
4. Focalização: indicar possíveis atributos em relação a sua relevância;
5. Congruência: harmonização entre a expectativa e a disponibilidade dos dados

Trabalhos Relacionados

A literatura apresenta diferentes abordagens sobre a relação entre padrões alimentares e depressão. Alguns estudos investigam padrões dietéticos derivados empiricamente e sua relação com transtornos psicológicos (Hossein-zadeh & Vafa). Outros discutem a associação entre dieta, depressão e fatores genéticos e ambientais (Cheng & Chu). Há também evidências de que dietas mediterrâneas apresentam associação não linear com sintomas depressivos (Fan & Zhao).

Revisões indicam mecanismos fisiológicos, neuroquímicos e inflamatórios pelos quais nutrientes e padrões alimentares podem modificar a saúde mental (Gadelha de Araújo; Brisotto et al., 2022). Além disso, adaptações do índice PHDI para prevenção da depressão têm sido exploradas como ferramentas úteis (Tan & Li). Novas abordagens com modelos explicáveis têm aproximado análises nutricionais de algoritmos interpretáveis para melhor compreensão de fatores preditivos da depressão (Hossein-zadeh Kasani & Lee; Huang & Huang).


Materiais e Métodos

Descrição da Base de Dados

Os dados analisados neste estudo têm como origem a *Pesquisa Nacional de Saúde* (PNS 2019), conduzida pelo Instituto Brasileiro de Geografia e Estatística (IBGE). A PNS é um inquérito domiciliar de abrangência nacional que reúne informações detalhadas sobre o estado de saúde da população brasileira, incluindo aspectos sociodemográficos, hábitos de vida, utilização de serviços de saúde e diversos indicadores relacionados às condições físicas e mentais dos indivíduos.


O conjunto de dados originalmente disponibilizado pela pesquisa contém um total de 293.726 observações e 1.087 variáveis.

Entendimento do Problema e Seleção Conceitual de Atributos



Compreender o domínio do problema constitui uma etapa essencial em qualquer processo de descoberta de conhecimento, pois fundamenta a criação de modelos de aprendizado capazes de representar com maior fidelidade a realidade estudada.

Considerando a elevada quantidade de variáveis presentes na PNS 2019, torna-se indispensável realizar uma seleção conceitual de atributos, de modo a direcionar a análise para os elementos mais significativos. A Figura apresenta a seguir é o modelo conceitual elaborado para orientar este estudo.



Como desdobramento desse processo, foram escolhidos 143 atributos com base no modelo conceitual definido. A tabela a seguir apresenta os módulos correspondentes a esses atributos.


Table 1: *

Quantidade de Atributos Seleccionados por Módulo	
Módulo	Quantidade de Atributos
P – Estilos de Vida	66
N – Percepção do Estado de Saúde	12
C – Características Gerais dos Moradores	4
V – Variáveis Derivadas	2
J – Utilização/Atendimento de Saúde	5
H – Atendimento Médico	2
A – Informações do Domicílio	11
E – Características de Trabalho	7
M – Características de Trabalho e Social	17
G – Pessoas com Deficiência	4
Q – Doenças Crônicas	13
Total Geral	143

Pré-Processamento e preparação de dados

Seleção de Registros

Com base na frequência acumulada de casos depressivos por faixa etária, definiu-se o recorte analítico considerando indivíduos entre 30 e 70 anos.



Eliminação de Dados Ausentes

Na base de dados original, composta por 150 atributos, foi identificado um padrão relevante: 79 variáveis apresentavam exatamente o mesmo volume de registros ausentes — 76.372 observações em falta em cada uma delas. Esse número representa mais de 50% do total de registros disponíveis por atributo, configurando uma perda estrutural severa. Assim, optou-se pela remoção completa desses 76.372 registros, reduzindo o tamanho do conjunto de dados, mas garantindo maior consistência e confiabilidade analítica.

Após a limpeza inicial e as transformações, o conjunto de dados resultante ainda apresentava pequenos percentuais de valores ausentes em alguns atributos, variando entre 0,02% e 8,3%. Esses valores faltantes estavam em proporções manejáveis, permitindo a aplicação de técnicas de imputação.

Para lidar com esses casos, foi empregada a imputação por *K-Nearest Neighbors* (KNN), método que estima valores ausentes com base na similaridade entre indivíduos em um espaço multidimensional.

Eliminação de Outliers

A presença de valores extremos (outliers) pode distorcer de forma significativa as medidas de tendência central e dispersão, além de impactar negativamente o desempenho de modelos estatísticos e de aprendizado de máquina.

A técnica utilizada foi o método do *Interquartile Range* (IQR) nos atributos: `peso`, `altura`, `qtd_doses`, `num_consultas_medico`, `max_doses_um_dia`. O procedimento consiste em calcular o primeiro quartil ($Q1$) e o terceiro quartil ($Q3$), que representam, respectivamente, os percentis de 25% e 75% da distribuição. A partir deles, obtém-se o intervalo interquartil:

$$IQR = Q3 - Q1$$


Em seguida, definem-se os limites inferior e superior considerados aceitáveis:

$$\text{Limite Inferior} = Q1 - 1.5 \times IQR$$

$$\text{Limite Superior} = Q3 + 1.5 \times IQR$$

Qualquer observação com valor abaixo do limite inferior ou acima do limite superior é classificada como outlier e removida da análise. Essa estratégia preserva a estrutura principal da distribuição e reduz a influência de valores anômalos, permitindo uma comparação mais justa entre os valores *antes* e *depois* do tratamento.

Segue abaixo o exemplo do boxplot e do recorte de outlier feito em um dos atributos



Transformações dos Atributos

`Vitaminas`, `Minerais_e_Antioxidantes`, `Proteinas`, `Plantas_e_Fibras`, `Acucar`, `Alimentos_Gordurosos_Processados_Industrializados` Foram utilizados diversos códigos

do bloco alimentar, incluindo variáveis binárias (P006XX), número de dias por semana (P006, P00901, P01101, P013, P015, P01601, P018, P02001, P02002, P023, P02501, P02602) e frequências diárias (P01001, P019). Para cada categoria alimentar, todas as variáveis componentes foram normalizadas e agregadas para formar um escore representativo do padrão de consumo.

Primeiro, cada variável foi normalizada conforme seu tipo: - variáveis binárias: $x = 1$ se resposta positiva, 0 caso contrário; - variáveis em dias por semana: $x = \frac{\text{dias}}{7}$; - variáveis em vezes por dia: $x = \frac{\text{vezes}-1}{2}$.

Em seguida, para cada categoria C , calculou-se o escore médio:

$$S_C(i) = \frac{1}{n_C} \sum_{j=1}^{n_C} x_{ij},$$

onde n_C é o número de códigos pertencentes à categoria.

O vetor de escores S_C foi então particionado em três níveis por meio do algoritmo K-Means:

$$\hat{C}(i) = f(\text{KMeans}_3(S_C(i))),$$

com os centróides ordenados de forma crescente para produzir a classificação ordinal final:

$$1 = \text{baixo consumo}, \quad 2 = \text{consumo moderado}, \quad 3 = \text{alto consumo}.$$

Cada uma das seis variáveis finais (**Vitaminas**, **Minerais_e_Antioxidantes**, **Proteinas**, **Plantas_e_Fibras**, **Acucar**, **Alimentos_Gordurosos_Processados_Industrializados**) foi criada seguindo exatamente esse procedimento, substituindo todas as variáveis originais utilizadas em seu cálculo.

Suporte_Social A construção deste atributo utilizou os códigos M01401, M01501, M01601 e M01701. Inicialmente, M01401 e M01501 foram recodificados como contagens de suporte direto, enquanto M01601 e M01701 foram transformados em escores de frequência, de modo que valores maiores representassem maior interação social. Em seguida, os quatro componentes foram somados para formar um escore contínuo de suporte social. Por fim, esse escore foi convertido em um indicador categórico.

A regra geral de transformação pode ser descrita matematicamente da seguinte forma:

$$\text{Suporte_Social_score} = \underbrace{f(M01401)}_{\text{família}} + \underbrace{f(M01501)}_{\text{amigos}} + \underbrace{g(M01601)}_{\text{freq. encontros}} + \underbrace{g(M01701)}_{\text{freq. grupos}}$$

onde

$$f(x) = \begin{cases} 0, & x = 0 \\ 1, & x = 1 \\ 2, & x = 2 \\ 3, & x = 3 \end{cases} \quad \text{e} \quad g(x) = \begin{cases} 4, & x = 1 \\ 3, & x = 2 \\ 2, & x = 3 \\ 1, & x = 4 \\ 0, & x \in \{5, 6\} \end{cases}$$

Após calcular o escore contínuo, a classificação final foi definida como:

$$\text{Suporte_Social} = \begin{cases} 1, & 0 \leq \text{score} \leq 4 \\ 2, & 5 \leq \text{score} \leq 8 \\ 3, & 9 \leq \text{score} \leq 14 \end{cases}$$

As categorias finais ficaram definidas como: 1 = baixo suporte social, 2 = suporte médio, 3 = suporte alto.

Atividade Física Este atributo foi construído a partir das variáveis P034, P035, P03701 e P03702. Inicialmente, calculou-se o tempo total semanal de prática de exercícios.

$$\text{Total_Minutes_Weekly}_i = (P03701_i \times 60 + P03702_i) P035_i.$$

Em seguida, a classificação final do nível de atividade física foi definida com base em P034 e no tempo semanal total calculado. A regra adotada é descrita pela função:

$$\text{Atividade_Fisica}_i = \begin{cases} 1, & \text{se não pratica atividade física,} \\ 2, & \text{se pratica, porém com menos de 150 min/sem,} \\ 3, & \text{se pratica com 150 min/sem ou mais.} \end{cases}$$

Situacao_Trabalho Foram utilizados os códigos E001, E002, E003, E004, E005, E011, E01401, M005010, M005011, M00601, M007, M008 e os indicadores de vulnerabilidade M011011, M011021, M011031, M011041, M011051, M011061, M011071. A transformação consistiu primeiro em identificar se a pessoa não trabalhava, depois se trabalhava, e por fim verificar, entre os que trabalhavam, condições de longa jornada ou vulnerabilidade ocupacional para separar um terceiro grupo.

A regra de transformação pode ser expressa da seguinte forma:

$$\text{Situacao_Trabalho} = \begin{cases} 1, & \text{se } (E001 = E002 = E003 = E004 = E005 = 2) \\ 2, & \text{se } \exists E_j = 1 \text{ e não houver vulnerabilidade} \\ 3, & \text{se } \exists E_j = 1 \text{ e } (E011 \in \{2, 3\} \vee M005010 = 1 \vee M007 = 1, \dots) \end{cases}$$

onde $E_j \in \{E001, E002, E003, E004, E005\}$ e $M011_k \in \{M011011, M011021, M011031, \dots\}$.

As categorias finais ficaram definidas como: 1 = não trabalha, 2 = trabalha, 3 = trabalha em condição de vulnerabilidade ou longa jornada.

Uso_Servicos_Saude Foram utilizados os códigos J01101, J012, J01301 e J014. A transformação consistiu em classificar o padrão de uso de serviços de saúde considerando consultas médicas, consultas odontológicas e a busca por outros atendimentos recentes.

A regra de transformação pode ser representada por:

$$U = \begin{cases} 3, & \text{se } (J014 = 1) \vee (J01101 = 1 \wedge J01301 = 1) \\ 2, & \text{se } (J01101 \in \{2, 3\}) \vee (J01301 \in \{2, 3\}) \\ 1, & \text{se } (J01101 \in \{4, 5\}) \vee (J01301 \in \{4, 5\}) \end{cases}$$

A variável **Uso_Servicos_Saude** recebe então o valor U , com a seguinte classificação final:

1 = uso muito baixo, 2 = uso moderado, 3 = uso frequente.

Foi feita este tipo parecido de esquema de agrupamento de atributos mas com outra

lógicas: **CONSUMO_DROGAS, DEFICIENCIA_FISICA, DOENCA_CRONICA, PROBLEMA_SONO, PENSAMENTOS_NEGATIVOS e AUTOAVALIACAO_SAUDE**

Moradia_Vulneravel Foram utilizados os códigos A001, A002010, A003010, A004010, A005010, A005012, A00601, A01501 e A016010. A transformação consistiu em verificar, para cada domicílio, a presença de qualquer condição de vulnerabilidade estrutural, ambiental ou de saneamento.

A regra de transformação pode ser escrita como:

onde $I(\cdot)$ é a função indicadora, que vale 1 quando a condição é verdadeira e 0 caso contrário.

A classificação final é dada por:

$$\text{Moradia_Vulneravel} = \begin{cases} 1, & \text{se } v = 0 \\ 2, & \text{se } v \geq 1 \end{cases}$$

As categorias finais ficaram definidas como: 1 = não vulnerável e 2 = vulnerável.

Cor/Raça O atributo utilizado neste processo foi o **C009 — Cor ou Raça**, originalmente categorizado como: 1 para branco, 2 para preto, 3 para amarelo, 4 para pardo, 5 para indígena e 9 para casos ignorados.

$$\text{manter}(C009) = \begin{cases} 1, & \text{se } C009 \neq 9, \\ 0, & \text{se } C009 = 9. \end{cases}$$

Em seguida, realizou-se o agrupamento de categorias para reduzir a dispersão da variável. A categoria *Amarelo* (3) foi incorporada à categoria *Branco* (1), enquanto *Indígena* (5) foi incorporada à categoria *Pardo* (4). Assim, o processo de recodificação pode ser descrito por:

$$C009' = \begin{cases} 1, & \text{se } C009 \in \{1, 3\}, \\ 2, & \text{se } C009 = 2, \\ 4, & \text{se } C009 \in \{4, 5\}. \end{cases}$$

Foi feita também este tipo parecido de esquema de agrupamento de valores com os atributos: **REND**A, **ESCOLARIDADE**, e **ESTADO_CIVIL**

Consumo_Alcool Foram utilizados os códigos P027, P02801, P029, P03201, P03202, P03301, P03302 e P03303. A variável final foi construída a partir de regras decisórias que combinam frequência de consumo, quantidade ingerida e presença de episódios de uso abusivo. O objetivo foi classificar os indivíduos em três níveis ordenados de consumo.

Primeiro, identificou-se se o indivíduo declarou não consumir álcool. Caso contrário, avaliou-se a presença de padrões de risco com base em binge drinking, frequência elevada, grande número de doses por ocasião e consequências negativas associadas ao uso.

Desse modo, a nova classificação final ficou definida como:

1 = não bebe, 2 = baixo/médio consumo, 3 = alto consumo.

Dicionário Após a Transformação

Na tabela a seguir, estão descritos os atributos presentes nas bases de dados após o pré-processamento e sua preparação de dados.

Atributo	Codificação
Atributos Binários	
Doenca_Cronica	1 = sim; 0 = não
Deficiencia_Fisica	1 = sim; 0 = não
Consumo_Drogas	1 = sim; 0 = não
Estado_Civil	1 = com companheiro; 0 = sem companheiro
Moradia_Vulneravel	1 = sim; 0 = não
Sexo	1 = homem; 0 = mulher
Depressao	1 = sim; 0 = não
Atributos Categóricos	
Cor/Raca	1 = branco; 2 = pardo; 3 = preto
Idade	1 = 30–40; 2 = 41–50; 3 = 51–60; 4 = 61–70
Altura	1 = <150 cm; 2 = 151–160 cm; 3 = 161–170 cm; 4 = 171–180 cm; 5 = >181 cm
Peso	1 = <60 kg; 2 = 61–70 kg; 3 = 71–90 kg; 4 = >91 kg
Regiao	centro-oeste; nordeste; norte; sudeste; sul
Atividade_Fisica	1 = não pratica; 2 = baixa; 3 = média/alta
Problemas_Sono	1 = nenhum dia; 2 = não frequente; 3 = frequente
Pensamentos_Negativos	1 = nenhum dia; 2 = não frequente; 3 = frequente
Autoavaliacao_Saude	1 = ruim; 2 = regular; 3 = boa
Suporte_Social	1 = baixo; 2 = médio; 3 = alto
Situacao_Trabalho	1 = não trabalha; 2 = trabalha normal; 3 = longa jornada/situação vulnerável
Uso_Servicos_Saude	1 = nunca ou +3 anos; 2 = não frequente; 3 = frequente
Vitaminas	1 = consumo baixo; 2 = médio; 3 = alto
Minerais_e_Antioxi....	1 = consumo baixo; 2 = médio; 3 = alto
Proteinas	1 = consumo baixo; 2 = médio; 3 = alto
Plantas_e_Fibras	1 = consumo baixo; 2 = médio; 3 = alto
Acucar	1 = consumo baixo; 2 = médio; 3 = alto
Alimentos_Gorduro....	1 = consumo baixo; 2 = médio; 3 = alto
Consumo_Alcool	1 = não bebe; 2 = baixo/médio; 3 = alto
Renda	1 = <0.5 salário; 2 = 0.5–1 salário; 3 = 1–2 salários; 4 = 2–3 salários; 5 = >3 salários
Escolaridade	1 = fundamental incompleto; 2 = fundamental completo / médio incompleto; 3 = médio completo / superior incompleto; 4 = superior completo

Table 2: Descrição dos atributos e suas codificações.

Resultados

Modelos e Parametrização

- **Preparação dos dados:** Realizou-se a divisão desses dados em subconjuntos de treinamento e teste.
- **Construção dos modelos com técnicas de balanceamento:** Para cada combinação entre método de balanceamento e modelo de classificação — no caso, Árvore de Decisão e Floresta Aleatória — foi estruturado um fluxo. Cada fluxo aplicava, em primeiro lugar, a técnica de reamostragem escolhida (como RUS, NearMiss, SMOTE, SMOTETomek, ADASYN associado a ENN ou ADASYN combinado com Tomek) e, posteriormente, ajustava o modelo propriamente dito. Essa abordagem permitiu analisar como diferentes estratégias de correção do desbalanceamento influenciam o aprendizado.
- **Ajuste fino dos modelos:** Para cada um desses fluxos, foi realizada uma busca sistemática pelos melhores parâmetros de configuração utilizando o Randomized-SearchCV, útil para parametrizações grandes.
- **Avaliação do desempenho:** Foram registradas métricas fundamentais para comparação entre as abordagens, como acurácia, precisão média, revocação média e $f1$ -macro.

Table 3: Divisão para treinamento/validação e teste


Classe	Original	Treino	Teste
1 (Com depressão)	6.553	4.587	1.966
0 (Sem depressão)	57.361	40.153	17.208
Total	63.914	44.740	19.174

O processo de treinamento foi realizado com validação-cruzada de 5 dobras

Desempenho e Balanceamento

O melhor resultado global foi alcançado pelo balanceamento do **SMOTETomek + RandomForest**. No entanto, métodos que ampliam a classe minoritária por meio da geração sintética de exemplos, baseados em interpolações de observações reais, podem produzir instâncias artificiais que nem sempre representam condições plausíveis, levando a distorções e comprometendo a interpretação fiel do desempenho.

Dessa forma, o balanceamento **RUS** mostrou-se o mais adequado, pois não introduz dados artificiais e preserva integralmente a coerência com o cenário real analisado.



Combinação	Accuracy	Precision_Macro	Recall_Macro	F1_Macro
SMOTETomek + RandomForest	0.840782	0.656483	0.760033	0.684754
SMOTE + RandomForest	0.840782	0.656483	0.760033	0.684754
SMOTETomek + DecisionTree	0.861226	0.663431	0.719758	0.684562
SMOTE + DecisionTree	0.861226	0.663431	0.719758	0.684562
ADASYN+Tomek + RandomForest	0.838435	0.655363	0.762258	0.683637
ADASYN+Tomek + DecisionTree	0.804537	0.636762	0.768516	0.658673
RUS + RandomForest	0.755567	0.627308	0.794635	0.631975
RUS + DecisionTree	0.730900	0.620653	0.792351	0.614549
ADASYN+ENN + RandomForest	0.718905	0.618090	0.791619	0.606420
ADASYN+ENN + DecisionTree	0.718801	0.617305	0.789352	0.605719
NearMiss + DecisionTree	0.699140	0.584747	0.705042	0.568312
NearMiss + RandomForest	0.662790	0.576092	0.692924	0.544061

Table 4: Resultados de métricas para todas as combinações testadas

Interpretação dos Resultados

O modelo escolhido RUS, tem uma precisão de 75,5%, apresenta alta precisão para a classe “sem depressão” ($precision_0 \approx 0,98$).

Para a classe “com depressão”, observa-se um comportamento misto. O *recall* é elevado ($\approx 0,84$), indicando que o modelo consegue identificar a maior parte das pessoas que realmente têm depressão. No entanto, a precisão dessa classe é baixa ($\approx 0,28$), de modo que apenas 28% dos indivíduos classificados como deprimidos realmente pertencem a essa classe. Isso implica um grande número de falsos positivos (4 375 casos).

Os 4 375 falsos positivos representam aproximadamente 25,5% dos indivíduos não deprimidos. Assim, muitas pessoas sem depressão seriam indevidamente sinalizadas como deprimidas.

Por outro lado, o modelo gera 312 falsos negativos (15,6% dos indivíduos deprimidos). Embora represente risco clínico por deixar de identificar alguns casos, esse valor é relativamente pequeno comparado ao total de deprimidos, refletindo o *recall* elevado.

Em síntese, o modelo apresenta alta sensibilidade para identificar pessoas com depressão, mas baixa precisão, resultando em elevado número de falsos alarmes.

Interpretação de regras da árvore relacionadas a hábitos alimentares

A seguir, são apresentadas três regras extraídas da árvore de decisão e suas interpretações práticas no contexto dos hábitos alimentares.

- **Regra 1: baixa ingestão de plantas/fibras e alto consumo de alimentos processados** **Padrão:** quando $Plantas_e_Fibras \leq 0.5$ e $Alimentos_Processados > 0.5$. **Interpretação:** indivíduos com consumo reduzido de fibras e vegetais, e consumo de alimentos ultraprocessados, são mais comuns em perfis depressivos.
- **Regra 2: baixa ingestão de vitaminas e alto consumo de álcool/drogas** **Padrão:** nós que separam indivíduos por *Vitaminas*, *Consumo_Alcool* e *Consumo_Drogas*. **Interpretação:** o modelo identifica associação entre baixa adesão a micronutrientes e comportamentos de consumo de substâncias, indicando que tais padrões estão relacionados à classe “com depressão”.
- **Regra 3: maior consumo de proteínas e prática de atividade física** **Padrão:** ramos contendo atributos como *Proteinas* e *Atividade_Fisica*. **Interpretação:** hábitos relacionados à alimentação mais equilibrada e prática de atividade física estão correlacionados no modelo sendo mais comuns em perfis não depressivos.

Conclusões

O Hábito Alimentar

Indivíduos com sintomas depressivos apresentam padrões alimentares comprometidos que parecem decorrer das próprias manifestações clínicas da depressão. Sintomas como anedonia (redução do prazer), apatia e diminuição da motivação tendem a reduzir o engajamento em práticas alimentares saudáveis e a favorecer escolhas com retorno hedônico imediato — por exemplo, alimentos ricos em açúcar, gordura e ultraprocessados — que proporcionam alívio ou recompensa rápida, ainda que de curtíssimo prazo. Ao mesmo tempo, para parte dos indivíduos, a depressão pode se manifestar como perda de apetite e redução da ingestão, o que reforça a heterogeneidade das mudanças alimentares associadas ao quadro clínico (Brisotto et al., 2022; Gadelha de Araújo; Chen & Cao).

Menor consumo relativo de plantas, fibras e micronutrientes, concomitante a maior presença de alimentos industrializados e episódios de consumo por recompensa emocional, aparecem com maior frequência entre pessoas que relatam sintomas depressivos. Observações semelhantes aparecem em estudos que discutem mecanismos comportamentais e neurobiológicos que aproximam dieta e sintomas depressivos — por exemplo, alterações na motivação de recompensa, regulação emocional e regulação do apetite. (Hosseinzadeh & Vafa; Fan & Zhao; Zhu & Zhang).

Limitações e Pontos

A principal restrição decorre da **baixa representatividade de pessoas deprimidas na PNS 2019** e também da falta de atributos vindo dos modelo conceitual que não está presente na base, o que reduz a capacidade de aprendizado do modelo e limita a identificação de padrões específicos, como já apontado em estudos que dependem de maior equilíbrio entre classes para análises confiáveis Silva & Zárte Galvez.

A alimentação não atua como causa direta da depressão; na maior parte dos casos, ocorre o contrário: sintomas depressivos influenciam hábitos alimentares, podendo resultar em padrões alimentares inadequados, enquanto a dieta funciona predominantemente como fator protetor ou agravante – e não como gatilho primário Chen & Cao; Hosseinzadeh & Vafa; Brisotto et al. (2022); Gadelha de Araújo; Fan & Zhao.

Além disso, variáveis combinadas — como estado civil, condições de moradia, suporte social e entre outras — podem tornar o modelo excessivamente generalizado. Isso ocorre porque tais atributos capturam efeitos amplos e contextuais, dificultando a sensibilidade

do modelo para **padrões mais específicos** ou subgrupos menos frequentes. Cheng & Chu.

Somado a isso, a etapa de compreensão do domínio reforça que a modelagem depende essencialmente da qualidade e profundidade dos dados disponíveis Zárate, e a ausência de variáveis clínicas detalhadas, comportamentais e longitudinais limita o alcance das inferências possíveis. Estudos recentes ressaltam que modelos preditivos de depressão exigem conjuntos de dados mais ricos e diversificados para evitar vieses estruturais Hosseinzadeh Kasani & Lee; Huang & Huang; Zhu & Zhang.

Em síntese, as limitações decorrem tanto da natureza dos dados quanto da complexidade da relação entre alimentação, comportamento e saúde mental, o que reforça a necessidade de bases mais completas e metodologias específicas para populações minoritárias ou com características clínicas complexas.

Resumo e Estudos Futuros

A aplicação do método CAPTO foi útil para estruturar a compreensão do domínio e orientar a seleção conceitual de atributos — etapas que contribuíram para gerar variáveis interpretáveis e sensíveis às dimensões comportamentais relevantes para este tema (Zárate; Silva & Zárate Galvez)..

Os resultados apontam que a presença de sintomas depressivos tende a estar associada a: (i) menor consumo de alimentos in natura (plantas e fibras) e micronutrientes; (ii) maior consumo de alimentos ultraprocessados e ricos em açúcar/gordura; e (iii) padrões de consumo que podem ser explicados por busca de recompensa imediata e diminuição do prazer em atividades cotidianas — fatores comportamentais típicos da depressão.

Considerando o caráter descritivo do trabalho e as limitações impostas pelo desenho observacional, recomenda-se que intervenções públicas e clínicas levem em conta não apenas a informação nutricional, mas também as barreiras motivacionais e emocionais que dificultam escolhas alimentares saudáveis em pessoas deprimidas. Estratégias que aumentem a conveniência e o reforço positivo de escolhas saudáveis (por exemplo, facilitação de acesso, refeições prontas saudáveis, intervenções de ativação comportamental integradas à orientação nutricional) podem ser caminhos promissores. Por fim, estudos longitudinais, avaliações clínicas complementares e ensaios de intervenção são necessários para melhor compreender a dinâmica temporal entre sintomas depressivos e alterações alimentares, bem como para testar medidas que amenizem o impacto da depressão sobre a alimentação. (Chen & Cao; Fan & Zhao; Tan & Li; Brisotto et al., 2022)

References

- Zárate, L. E. *CAPTO - A Method for Understanding Problem Domains for Data Science Projects.*
- Silva, P. H. R., & Zárate Galvez, L. E. *Utilizando Modelos de Machine Learning para a Caracterização da Depressão em Adultos no Brasil.*
- Chen, H., & Cao, Z. *The associations of dietary patterns with depressive and anxiety symptoms: a prospective study.*
- Hosseinzadeh, M., & Vafa, M. R. *Empirically derived dietary patterns in relation to psychological disorders.*
- Cheng, B., & Chu, X. *Dietary Habit Is Associated with Depression and Intelligence: Observational and $G \times E$ analyses.*
- Brisotto, E., et al. (2022). *Depressão, ansiedade e estresse e o comportamento alimentar.*
- Gadelha de Araújo, P. H. *Influência da dieta na saúde mental e desempenho cognitivo – revisão da literatura.*
- Fan, Y., & Zhao, L. *Non-linear association between Mediterranean diet and depressive symptom in U.S. adults.*
- Tan, J.-x., & Li, Q.-z. *Evaluating and modifying the PHDI for depression prevention: insights from NHANES 2005–2018.*
- Hosseinzadeh Kasani, P., & Lee, J. E. *Evaluation of nutritional status and clinical depression classification using an explainable machine learning method.*
- Huang, A. A., & Huang, S. Y. *Exploring Depression and Nutritional Covariates Amongst US Adults using SHAP.*
- Zhu, Y., & Zhang, R. *Digital Dietary Behaviors in Individuals With Depression: Real-World Behavioral Observation.*