

Hipertensão e Hiperparâmetros: aplicação de aprendizado de máquina na Pesquisa Nacional de Saúde 2019

LUCAS DO NASCIMENTO, Pontifícia Universidade Católica de Minas Gerais, Brasil

Esta entrega de trabalho prático apresenta uma análise preliminar de aprendizado de máquina para predição de hipertensão arterial utilizando dados da Pesquisa Nacional de Saúde (PNS) de 2019. Aplicamos o método CAPTO para mapeamento conceitual do problema e comparamos o desempenho de sete algoritmos de classificação: Decision Tree, Random Forest, Gradient Boosting, SVM, Naive Bayes, KNN e Logistic Regression. Realizamos pré-processamento completo dos dados incluindo tratamento de valores faltantes, detecção de outliers, balanceamento de classes com SMOTE e normalização. O ajuste de hiperparâmetros foi feito através de Grid Search com validação cruzada.

CCS Concepts: • **Computing methodologies** → **Machine learning**; • **Applied computing** → **Health informatics**.

Additional Key Words and Phrases: Hipertensão arterial, Aprendizado de máquina, PNS 2019, problemas de classificação

ACM Reference Format:

Lucas do Nascimento. 2025. Hipertensão e Hiperparâmetros: aplicação de aprendizado de máquina na Pesquisa Nacional de Saúde 2019. *ACM Trans. Graph.* 37, 4, Article 111 (November 2025), 5 pages. <https://doi.org/XXXXXXX.XXXXXXX>

1 Introdução

A hipertensão arterial é uma doença crônica que afeta milhões de brasileiros e representa um dos principais fatores de risco para doenças cardiovasculares [Barroso et al. 2021; Silva et al. 2024]. Segundo as Diretrizes Brasileiras de Hipertensão Arterial, a identificação precoce e o controle adequado da hipertensão podem reduzir significativamente a ocorrência de complicações graves como infarto e acidente vascular cerebral [Jardim 2018].

Neste contexto, técnicas de aprendizado de máquina podem auxiliar na identificação de padrões e fatores de risco associados à hipertensão [Alizargar et al. 2022; Asadullah et al. 2023]. Este trabalho tem como objetivo desenvolver e comparar modelos de classificação capazes de prever a presença de hipertensão arterial em indivíduos com base em características disponíveis na Pesquisa Nacional de Saúde (PNS) de 2019.

Complexidade do Problema: A hipertensão é uma condição multifatorial influenciada por genética, estilo de vida, dieta e outros fatores não totalmente capturados pelos atributos disponíveis

Author's Contact Information: Lucas do Nascimento, lucasrafael.pessoan@gmail.com, Pontifícia Universidade Católica de Minas Gerais, Curso de Ciência de Dados e Inteligência Artificial, Belo Horizonte, Minas Gerais, Brasil.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

© 2025 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM 1557-7368/2025/11-ART111

<https://doi.org/XXXXXXX.XXXXXXX>

em todas as pesquisas. [Fonseca et al. 2008; Mikael et al. 2017]. Fatores emocionais e comportamentais também exercem influência significativa [Park et al. 2023].

Fatores de Risco Conhecidos: A literatura indica que obesidade [Barroso and Souza 2020; Ferreira et al. 2018; Jardim 2019], sedentarismo [Cao et al. 2019; Sharman et al. 2019; Wendt et al. 2019], e aspectos nutricionais [Farshidi et al. 2020; Jabbari et al. 2022; Savica et al. 2010] são fatores de risco para hipertensão.

1.1 Objetivos

O objetivo principal deste trabalho é avaliar a capacidade de diferentes algoritmos de aprendizado de máquina em prever hipertensão arterial. Especificamente, buscamos:

- Aplicar o método CAPTO para mapear conceitualmente o domínio do problema;
- Realizar pré-processamento adequado dos dados da PNS 2019;
- Treinar algoritmos de classificação ;
- Comparar o desempenho dos modelos;

2 Fundamentação Teórica

2.1 Método CAPTO

O método CAPTO (Contextualização, Aspectos, Propriedades, Termos e Ontologias) é uma abordagem estruturada para mapeamento conceitual de domínios complexos [Zárate et al. 2023]. Neste trabalho, utilizamos o CAPTO para, antes de trabalhar com os atributos da PNS 2019, definir um modelo base para seleção de variáveis. Dividimos o problema em quatro dimensões principais:



Fig. 1. Modelo conceitual

- **Características do Indivíduo:** dados demográficos, antropométricos e de escolaridade
- **Saúde Física e Mental:** condições de saúde e percepção de bem-estar

- **Genética:** histórico familiar (quando disponível)
- **Qualidade de Vida:** alimentação, condições socioeconômicas, atividade física, trabalho e sono

2.2 Algoritmos Utilizados

Ganho de Informação:

A entropia de um conjunto S é definida como:

$$H(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

O ganho de informação de um atributo A é:

$$IG(S, A) = H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

Gain Ratio:

$$\text{GainRatio}(S, A) = \frac{IG(S, A)}{\text{SplitInfo}(S, A)}$$

onde:

$$\text{SplitInfo}(S, A) = - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} \log_2 \left(\frac{|S_v|}{|S|} \right)$$

Naive Bayes:

A probabilidade posterior da classe C_k dado um vetor de atributos $\mathbf{x} = (x_1, \dots, x_n)$ é:

$$P(C_k|\mathbf{x}) = \frac{P(C_k) \prod_{i=1}^n P(x_i|C_k)}{P(\mathbf{x})}$$

A classificação é dada por:

$$\hat{y} = \arg \max_k P(C_k) \prod_{i=1}^n P(x_i|C_k)$$

3 Metodologia

3.1 Base de Dados

Utilizamos dados da Pesquisa Nacional de Saúde (PNS) 2019, realizada pelo IBGE. Para este estudo, trabalhamos com:

- **Instâncias:** 53.149 registros
- **Atributos:** 28 features selecionadas
- **Variável alvo:** Q00201 (diagnóstico de hipertensão por médico)
- **Classes:** Hipertenso e Não Hipertenso
- **Distribuição:** 58% não hipertensos, 42% hipertensos

3.2 Pré-processamento

O pré-processamento dos dados seguiu as etapas de preenchimento de valores ausentes, combinação de atributos e discretização de faixas de valores.

No tratamento dos dados, as variáveis relacionadas ao trabalho ("Trabalhava de madrugada?" e "Trabalhava 24h seguidas?") tiveram seus valores ausentes imputados com "Não" através da operação "Fix Value". De forma similar, a variável de tabagismo "Já fumou no passado?" também recebeu a mesma estratégia de imputação, substituindo missing values por "Não". Por fim, para a variável "classificacao_imc", optou-se por remover completamente as linhas que continham valores ausentes através da operação "Remove Row",

garantindo que apenas registros com classificação válida de IMC fossem mantidos na base final.

O balanceamento de classes foi feito utilizando o método Under-sampling, de maneira que as classes de hipertensos e não hipertensos ficassem com a mesma quantidade de registros disponíveis para o treinamento do modelo. Vale ressaltar que, na fase de teste, é utilizada a base desbalanceada.

Tabela 1. Contagem de registros disponíveis por classe)

	Hipertensos	N/ Hipertensos
Pré undersampling	23383	13451
Pós undersampling	13451	13451




Fig. 2. TSN-e e distribuição de classes




Fig. 3. Importância dos atributos

Tabela 2. Matriz de confusão árvore de decisão, treinada com conjunto de 20% dos dados

	Predito: Neg.	Predito: Pos.
Real: Negativo	2895	1735
Real: Positivo	1158	1578

4 Resultados

A árvore de decisão gerada no KNIME inicia dividindo o dataset com base em uma variável que possui o maior poder discriminatório segundo o critério de Gini, representando a característica mais importante para prever hipertensão nos dados da PNS 2019. Como o KNIME usa divisões binárias, cada nó interno se ramifica em exatamente dois nós filhos, onde o ramo esquerdo representa indivíduos que atendem à condição (exemplo: idade < 50 anos) e o ramo direito representa aqueles que não atendem (idade ≥ 50 anos). Os primeiros níveis capturam as relações mais fortes entre as variáveis preditoras e a hipertensão, sendo que cada divisão subsequente refina ainda mais a classificação, separando subgrupos cada vez mais homogêneos em relação à presença ou ausência de hipertensão. Se, por exemplo, o primeiro nó dividir por idade ou IMC (variáveis comumente importantes para hipertensão), isso indicaria que essa característica é o preditor mais relevante no conjunto de dados, enquanto as divisões subsequentes nos níveis 2 e 3 incorporariam outras variáveis como histórico familiar, hábitos alimentares ou atividade física, criando uma hierarquia de importância preditiva baseada na redução do índice de Gini.

Tabela 3. Métricas de desempenho por classe do modelo de árvore de decisão

Classe	Recall	Precision	F-measure
Não	0.625	0.714	0.667
Sim	0.577	0.476	0.522




Fig. 4. Primeiros níveis da árvore de decisão

A árvore de decisão apresentada utiliza o nível de consumo de sal como variável raiz, dividindo a população em dois grupos principais: aqueles com consumo adequado ou muito alto de sal (7645 sem hipertensão vs 13589 com hipertensão) e aqueles com consumo baixo ou muito baixo (4772 sem hipertensão vs 7842 com hipertensão).

No ramo esquerdo, onde o consumo de sal é adequado ou muito alto, a segunda divisão ocorre pela classificação de IMC, separando indivíduos com sobrepeso (3460 sem hipertensão vs 6919 com hipertensão) daqueles com peso normal ou baixo (4185 sem hipertensão vs 6669 com hipertensão). Para o grupo com sobrepeso, a terceira divisão considera a frequência de problemas de saúde, diferenciando entre quem não tem nenhum dia ou quase todos os dias com problemas (2364 sem vs 4221 com hipertensão) e aqueles com frequência intermediária (1602 sem vs 2698 com hipertensão), sendo que estes últimos se subdividem ainda pela questão do tabagismo. No ramo direito da árvore, onde o consumo de sal é baixo, a segunda divisão avalia se a pessoa trabalhava de madrugada, separando aqueles que não trabalhavam (4620 sem vs 7489 com hipertensão) dos que trabalhavam (208 sem vs 361 com hipertensão). O grupo que não trabalhava de madrugada se subdivide pela frequência de problemas de saúde, criando duas categorias com base no limiar de 0.50, enquanto o grupo que trabalhava de madrugada se subdivide pela frequência de consumo de refrigerante com limiar de 6.50 dias. A leitura da árvore deve ser feita de cima para baixo, seguindo os ramos conforme as condições são atendidas, onde os números entre parênteses indicam a distribuição de casos (não hipertensos/hipertensos) em cada nó terminal, permitindo avaliar a pureza da classificação e identificar os perfis de risco mais relevantes para o desenvolvimento de hipertensão arterial na população brasileira segundo os dados da PNS 2019.

Tabela 4. Matriz de confusão Random Forest, treinada com conjunto de 20% dos dados

	Predito: Neg.	Predito: Pos.
Real: Negativo	2889	1742
Real: Positivo	1163	1573

Tabela 5. Métricas de desempenho por classe do melhor modelo selecionado pelo Random Forest

Classe	Recall	Precision	F-measure
Não	0.624	0.713	0.665
Sim	0.575	0.475	0.520

5 Conclusão

A presente pesquisa demonstrou que a extração de conhecimento útil e não-óbvio a partir de dados de saúde pública depende fundamentalmente da combinação estratégica entre características dos dados de entrada, técnicas algorítmicas empregadas e ajuste criterioso de hiperparâmetros. Através da implementação e comparação de três algoritmos clássicos de árvores de decisão — CART, ID3 e C4.5 — sobre os microdados da Pesquisa Nacional de Saúde 2019, foi possível observar que cada técnica oferece perspectivas complementares sobre os padrões de doenças crônicas na população brasileira.

A escolha entre critérios de divisão como impureza de Gini, ganho de informação ou razão de ganho não é meramente técnica, mas possui implicações diretas na interpretabilidade e aplicabilidade dos resultados. O CART, com suas divisões binárias e uso de Gini, tende a gerar regras mais concisas e diretas, facilitando a tradução em políticas públicas específicas. O C4.5, por sua vez, ao lidar naturalmente com atributos multivalorados e valores ausentes, preserva a riqueza informacional dos dados epidemiológicos originais, permitindo identificar nuances nas relações entre variáveis socioeconômicas, comportamentais e de saúde.

O tratamento de valores ausentes através de imputação KNN e o balanceamento de classes via SMOTE revelaram-se etapas críticas não apenas para a performance preditiva, mas especialmente para evitar vieses sistemáticos que poderiam levar a interpretações equivocadas sobre grupos populacionais vulneráveis. A ausência de dados em pesquisas de saúde raramente é aleatória, e métodos ingênuos de tratamento podem mascarar ou amplificar desigualdades existentes. Seguindo o princípio de Fayyad, Piatetsky-Shapiro e Smyth, conhecimento útil em mineração de dados deve ser não apenas preciso, mas também compreensível, interessante e acionável. Neste contexto, cada regra extraída pelas árvores de decisão representa potencialmente uma ação concreta para gestores públicos. Por exemplo, regras que identifiquem combinações específicas de fatores de risco — como baixa escolaridade, sedentarismo e ausência de acompanhamento médico regular — em determinadas faixas etárias e regiões geográficas podem direcionar campanhas preventivas territorializadas e demograficamente focadas. A modularidade e transparência algorítmica implementadas neste trabalho permitem que pesquisadores e gestores não apenas apliquem os modelos, mas compreendam os mecanismos de decisão subjacentes. Isso é fundamental para a validação externa dos resultados e para a adaptação das estratégias conforme características locais. Uma regra que associe ausência de diagnóstico de hipertensão à falta de consultas preventivas, por exemplo, sugere intervenções no acesso aos serviços de atenção primária, enquanto regras envolvendo fatores comportamentais indicam necessidade de programas educacionais e de promoção da saúde.

Portanto, a utilidade do conhecimento extraído transcende a acurácia preditiva, materializando-se na capacidade de transformar padrões estatísticos em intervenções em saúde pública baseadas em evidências, direcionadas e mensuráveis. O diferencial metodológico desta pesquisa reside precisamente na ponte estabelecida entre rigor algorítmico e aplicabilidade prática, demonstrando que a escolha consciente de técnicas e parâmetros não é um exercício puramente acadêmico, mas um componente essencial para a geração de conhecimento verdadeiramente transformador no contexto da saúde coletiva brasileira.

Acknowledgments

Agradeço ao Laboratório de Inteligência Computacional Aplicada da PUC Minas pelo apoio e orientação, e aos professores do curso de Ciência de Dados.

Referências

- Azadeh Alizargar, Tan-Hsu Tan, Yang-Lang Chang, and Mohammad Alkhaleefah. 2022. Hypertension Disease Predictions with Various Models Using Data Science Framework. *ICMHI* (2022). doi:10.1145/3545729.3545751
- Md. Asadullah, Md. Murad Hossain, Sabrina Rahaman, Muhammad Saad Amin, Mst Sharmin Akter Sumy, Md Yasin Ali Parh, and Mohammad Amzad Hossain. 2023. Evaluation of machine learning techniques for hypertension risk prediction based on medical data in Bangladesh. *Indonesian Journal of Electrical Engineering and Computer Science* (2023). doi:10.11591/IJEECS.V31.I3.PP1794-1802
- Weimar Kunz Sebba Barroso, Cibele Isaac Saad Rodrigues, Luiz Aparecido Bortolotto, Marco Antônio Mota Gomes, Andréa Araújo Brandão, Audes D. M. Feitosa, Carlos Alberto Machado, Carlos Eduardo Poli-de-Figueiredo, Celso Amodeo, Décio Mion, Eduardo Costa Duarte Barbosa, Fernando Nobre, Isabel Cristina Britto Guimarães, José Fernando Vilela-Martin, Juan Carlos Yugar-Toledo, Maria Eliane Campos Magalhães, Mário Fritsch Neves, Paulo César Brandão Veiga Jardim, Roberto Dischinger Miranda, Rui Póvoa, Sandra Cristina Pereira Costa Fuchs, Alexandre Alessi, Alexandre Jorge Gomes de Lucena, Álvaro Avezum, Ana Luíza Lima Sousa, Andrea Pio-Abreu, Andrei C. Spósito, Ângela Maria Geraldo Pierin, Annelise Machado Gomes de Paiva, A Spinelli, Armando da Rocha Nogueira, N Ludovico, Bruna Eibel, C. L. M. Forjaz, Cláudia Regina de Oliveira Zanini, Cristiane Bueno de Souza, Dilma do Socorro Moraes de Souza, Eduardo Augusto Fernandes Nilson, Elisa Franco de Assis Costa, Elizabete Viana de Freitas, Elizabeth da Rosa Duarte, Elizabeth Silaid Muxfeldt, E Lima Júnior, Érika Maria Gonçalves Campana, Evandro José Cesarino, Fabiana Angelo Marques, Fábio Argenta, Fernanda Marciano Fernandes Nilson, Fernanda Spadotto Baptista, Fernando Antônio de Almeida, Flávio Borelli, Flávio Danni Fuchs, Frida Liane Plavnik, Gil F. Salles, Gilson Soares Feitosa, Giovâni Vieira da Silva, Grazia Maria Guerra, Heitor Moreno, Helius Carlos Finimundi, Isabela de Carlos Back, João Bosco Oliveira, João Roberto Gemelli, José Geraldo Mill, JM Ribeiro, Leda Lotaif, L COSTA, Lucélia Batista Neves Cunha Magalhães, Luciano F. Drager, Luís Cuadrado Martin, Luiz César Nazário Scala, Madson Q. Almeida, MMG Gowdak, Márcia Regina Simas Torres Klein, Marcus Vinicius Bolívar Malachias, Maria Cristina Caetano Kuschner, Maria Eliete Pinheiro, Mário Henrique Elesbão de Borba, Osni Moreira, Oswaldo Passarelli, Otávio Rizzi Coelho, Priscila Valverde de Oliveira Vitorino, Renault Mattos Ribeiro, Roberto Esporcatte, Roberto Jorge da Silva Franco, Rodrigo Pinto Pedrosa, Rogério Andrade Mulinari, Rogério Baumgratz de Paula, Rogério Toshiro Passos Okawa, Ronaldo Fernandes Rosa, Sandra L. Amaral, Sebastião Rodrigues Ferreira Filho, Sérgio Kaiser, Thiago Veiga Jardim, Vanildo da Silva Guimarães Neto, Vera Hermina Kalika Koch, Wille Oigman, and Wilson Nadruz. 2021. Diretrizes Brasileiras de Hipertensão Arterial – 2020. *Arquivos Brasileiros de Cardiologia* (2021). doi:10.36660/ABC.20201238
- Weimar Kunz Sebba Barroso and Ana Luíza Lima Souza. 2020. Obesidade, Sobrepeço, Adiposidade Corporal e Risco Cardiovascular em Crianças e Adolescentes. *Arquivos Brasileiros de Cardiologia* (2020). doi:10.36660/ABC.20200540
- Liujiao Cao, Xiuxia Li, Peijing Yan, Xiaoqin Wang, Meixuan Li, Rui Li, Xiue Shi, Xingrong Liu, and Kehu Yang. 2019. The effectiveness of aerobic exercise for hypertensive population: A systematic review and meta-analysis. *The Journal of Clinical Hypertension* (2019). doi:10.1111/JCH.13583
- Hossein Farshidi, Marzieh Nikparvar, Farkhondeh Razmpour, Farideh Dastsouz, Asma Zadeh Abbasi, and Roghaye Ezati Rad. 2020. The Relationship Between Hypertension and Socioeconomic Status and Food Intake. *Hormozgan Medical Journal* (2020). doi:10.5812/HMJ.97665
- Arthur Pate de Souza Ferreira, Célia Landmann Szwarcwald, and Giseli Nogueira Damascena. 2018. Prevalence of obesity and associated factors in the Brazilian population: a study of data from the 2013 National Health Survey. *Revista brasileira de epidemiologia = Brazilian journal of epidemiology* (2018). doi:10.1590/1980-549720190024
- Fabiana de Cássia Almeida Fonseca, Renata Zumerle Coelho, Rodrigo Nicolato, Leandro Fernandes Malloy-Diniz, and Humberto Corrêa da Silva Filho. 2008. A influência de fatores emocionais sobre a hipertensão arterial. (2008). doi:10.1590/S0047-20852009000200011
- Masoumeh Jabbari, Hassan Eini-Zinab, Ehsan Safaei, Faezeh Poursoleiman, Bahareh Amini, Mina Babashahi, Meisam Barati, and Azita Hekmatdoost. 2022. Determination of the level of evidence for the association between different food groups/items and dietary fiber intake and the risk of cardiovascular diseases and hypertension: An umbrella review. *Nutrition Research* (2022). doi:10.1016/J.NUTRES.2022.12.011
- Paulo César Brandão Veiga Jardim. 2018. The Brazilian Society of Cardiology and Hypertension: It's Time for Action. *Arquivos brasileiros de cardiologia* (2018). doi:10.5935/ABC.20180189
- Paulo César Brandão Veiga Jardim. 2019. Overweight, the Cardiovascular Risk of the Century. *Arquivos Brasileiros De Cardiologia* (2019). doi:10.5935/ABC.20190171
- Luana de Rezende Mikael, Anelise Machado Gomes de Paiva, Marco Mota Gomes, Ana Luíza Lima Sousa, Paulo César Brandão Veiga Jardim, Priscila Valverde de Oliveira Vitorino, Maicon Borges Euzébio, Wátila de Moura Sousa, and Weimar Kunz Sebba Barroso. 2017. Vascular Aging and Arterial Stiffness. *Arquivos brasileiros de cardiologia* (2017). doi:10.5935/ABC.20170091
- Sung-Eun Park, Wi-Young So, Yun-Sun Kang, and Jong-Hyun Yang. 2023. Relationship between Perceived Stress, Obesity, and Hypertension in Korean Adults and Older

- Adults. *Healthcare* (2023). doi:10.3390/HEALTHCARE11162271
- Vincenzo Savica, Guido Bellinghieri, and Joel D. Kopple. 2010. The effect of nutrition on blood pressure. *Annual review of nutrition* (2010). doi:10.1146/ANNUREV-NUTR-010510-103954
- James E. Sharman, Neil A. Smart, Jeff S. Coombes, and Michael Stowasser. 2019. Exercise and sport science australia position stand update on exercise and hypertension. *Journal of Human Hypertension* (2019). doi:10.1038/S41371-019-0266-Z
- Djanir Rodrigues da Silva, Hélio Marco Pereira Lopes Júnior, and Luana Guimarães da Silva. 2024. Fatores de risco em indivíduos com Hipertensão Arterial. *Revista Ibero-Americana de Humanidades, Ciências e Educação* (2024). doi:10.51891/REASE.V10I9.15805
- Andrea Wendt, Wellington Roberto Gomes de Carvalho, Inácio Crochemore-Silva, and Grégore I. Mielke. 2019. Preferências de atividade física em adultos brasileiros: resultados da Pesquisa Nacional de Saúde. *Revista Brasileira de Atividade Física Saúde* (2019). doi:10.12820/RBAFS.24E0079
- Luis E. Zárate, Bruno Petrocchi, Carlos D. Maia, Caio Felix, and Marco Paulo S. Gomes. 2023. CAPTO - A method for understanding problem domains for data science projects. *Concilium* (2023). doi:10.53660/CLM-1815-23M33

Received 08 Novembro 2025

Categoria	Código Original	Nome Descritivo	Descrição
Condições de Saúde	Q00201	Hipertenso?	Variável target
Dados Demográficos	D001	Sabe ler e escrever?	Removida no pré-processamento
Estilo de Vida	P02002	Frequência refrigerante	Mantida como numérica
Estilo de Vida	P02601	Nível de consumo de sal	Mantida como numérica
Estilo de Vida	P02602	Frequência consumo de álcool	Mantida como categórica, depois sofrendo label encoder.
Estilo de Vida	P034	Praticou esportes nos últimos 3 meses?	Mantida categórica e transformada em label encoder
Estilo de Vida	P04001	Frequência trajetos a pé	Mantida como numérica
Estilo de Vida	P044	Faz esforço físico nas tarefas de casa?	Removida do modelo
Estilo de Vida	P046	Mora perto de espaço de lazer público?	Mantida como categórica, depois sofrendo label encoder.
Estilo de Vida	P050	Fuma?	Mantida como categórica, depois sofrendo label encoder.
Estilo de Vida	P051	Já fumou no passado?	Removida no pré-processamento
Saúde Mental	N010	Frequência problemas para dormir	Mantida como numérica.
Saúde Mental	N011	Frequência fadiga	Mantida como numérica
Saúde Mental	N016	Frequência sentimentos depressivos	Mantida como numérica
Trabalho	M005010	Trabalhava de madrugada?	Removida no pré-processamento
Trabalho	M007	Trabalhava 24h seguidas?	Removida no pré-processamento
Trabalho	M01601	Se reuniu com outras pessoas para fazer atividade física	Mantida como categórica.
Variáveis Calculadas	classificacao_imc	Classificação IMC	Calculada com base no imc
Variáveis Calculadas	faixa_etaria	Faixa etária	Calculada com base na idade C006
Variáveis Calculadas	imc	IMC	Calculada com base na idade, gênero, altura e peso
Variáveis Derivadas	VDD004A	Nível de instrução mais alto alcançado	Removida no pré-processamento
Variáveis Derivadas	VDF004	Faixa de rendimento	Mantida como numérica
Variáveis Derivadas	VDM001	Faixa de tempo gasto em deslocamento	Removida no pré-processamento

Tabela 1: Dicionário de variáveis utilizadas na análise de predição de hipertensão