

Uso de Machine Learning para classificação de adultos com AVC: Uma análise comparativa

Rafael Cabral Campos Pinheiro¹

Prof. Luis Enrique Zarate Galvez, Cristiane Neri Nobre²

Ciências de Dados - Pontifícia Universidade Católica de Minas Gerais (PUC MINAS)

Resumo: O trabalho teve como objetivo aplicar técnicas de Machine Learning para conseguirmos fazer uma caracterização de pessoas com Acidente Vascular Cerebral (AVC). O nosso estudo utilizou como fonte de dados a base da Pesquisa Nacional da Saúde (PNS) 2019, a faixa etária que utilizamos foi de 55 a 77, chegamos nela a partir da frequência acumulada. Após isso foi realizado um grande processo de pré-processamento dos dados, desde a seleção de atributos até a remoção dos outliers. Com tudo isso, realizamos a otimização e a utilização dos hiper parâmetros para termos uma classificação eficaz. As conclusões foram bem significativas, indicando que os modelos apreenderam bem como detectar as pessoas com AVC, e conseguiram retornar algumas regras importantes para o diagnostico futuro desta doença.

Palavras-chave: Mineração de dados, saúde pública, balanceamento de dados.

ABSTRACT: This study aimed to apply Machine Learning techniques to characterize individuals affected by Stroke. We utilized data from the 2019 National Health Survey (PNS), focusing on the 55–77 age group, a range determined through cumulative frequency analysis. Following this, a comprehensive data pre-processing stage was conducted, encompassing everything from feature selection to outlier removal. We then proceeded with hyperparameter tuning to ensure effective classification. The findings were highly significant, demonstrating that the models effectively learned to detect stroke cases and yielded valuable rules for the future diagnosis of this condition.

Keywords: Data mining, public health, data balancing.

1. INTRODUÇÃO

O AVC, representa um dos maiores desafios na saúde atual, não apenas no Brasil, mas também em todo o mundo. Segundo a Sociedade Brasileira de Doenças Cerebrovasculares (SBAVC), apenas em 2024, estima-se que cerca de 85.427 pessoas morreram com decorrência desta patologia em nosso país. Com esses dados, podemos observar que este cenário de 2019 supera qualquer doença cardiovascular, como uma das principais causas de mortalidade no Brasil.

Diante disso, este contexto epidemiológico, tem como objetivo aplicar técnicas de Aprendizado de Máquina (Machine Learning) para conseguirmos caracterizar perfis

de risco, e que tenham como principal idade, as pessoas de 55 a 77 anos. Não iremos utilizar uma região específica do Brasil, já que os dados da classe minoritária, tem AVC, é bem pouca. Com tudo isso, iremos utilizar a otimização de modelos e ajuste de hiper parâmetros, que buscam identificar padrões de comportamento e de estilo de vida.

A análise proposta é se aprofundar nos fatores que tenham a relação de nossa doença com o consumo de alimentos saudáveis. Destaca-se apenas um atributo de alimento não saudável, “Consumo de sódio”, ele é necessário, já que a entropia de sua classe foi bem alta para o modelo preditivo.


Os dados utilizados neste estudo foram da base de dados da Pesquisa Nacional da Saúde (PNS) 2019, uma pesquisa de abrangência nacional e de base domiciliar. Esta base contém ingerências robustas sobre a saúde da população brasileira.

2. METODOS UTILIZADOS

2.1 SELEÇÃO DE ATRIBUTOS

A seleção de atributos foi feita a partir de uma análise dos dados presentes em cada coluna da PNS 201. Sendo assim, tivemos que fazer um modelo conceitual dos dados que iríamos usar, com ela ficou muito mais claro quais colunas que iriam ser utilizadas em nosso projeto.

Imagem 1 – Modelo conceitual do problema.



Fonte: Autoria própria.

2.2 DESCRIÇÃO DA BASE DE DADOS ANTES DO PRÉ-PROCESSAMENTO

A base de dados selecionada, é um conjunto de dados estruturado com 756.262 instâncias (linhas) e 210 (colunas). Do ponto de vista técnico (de armazenamento), todos os 60 atributos estão armazenados como tipos numéricos, divididos em 200 colunas do tipo inteiro (int64) e 10 colunas do tipo ponto flutuante (float64). Contendo 158.654.591 dados como “NA”.

Tabela 1 – Dimensões, aspectos vinculados para o domínio AVC

Descrição do Mapa Conceitual – Domínio de problema: AVC (Acidente Vascular Cerebral)		
Dimensão: Hábitos alimentares		
Aspectos (conhecimento explícito e estudo científico vinculado)	Atributos associados ao aspecto	Atributos vinculados com as fontes de dados
Dieta: A Dieta e ingestão de alimentos e bebidas: hábitos alimentares impactam diretamente no risco de AVC. Estudos apontam que alto consumo de sódio, gorduras e bebidas açucaradas aumentam a probabilidade de desenvolver doenças cardiovasculares (Malik et al., 2010)	- Quais alimentos e bebidas são consumidos - Frequência do consumo - Quantidade consumida	Módulo P – Estilos de Vida: P6a até P26a, P6b até P24a (BD - PNS)
Dimensão Hábitos de saúde		
Tabagismo: O tabagismo é um dos principais fatores de risco para doenças cardiovasculares e AVC. O cigarro aumenta a pressão arterial, causa	- Consumo de cigarros industrializados, artesanais e outros derivados do tabaco - Frequência de consumo (quantidade/dia, tempo de hábito)	Módulo P – Estilos de Vida: P36a até P49a (BD – PNS)

aterosclerose e eleva a chance de isquemia cerebral (WHO, 2017).	Exposição ao fumo passivo	
Atividade física: A prática regular de atividade física reduz o risco de hipertensão, obesidade e diabetes, que são fatores de risco para o AVC (LaMonte et al., 2005).	- Frequência semanal da prática de atividades físicas - Tempo médio de duração - Tipo de atividade (leve, moderada, intensa)	Módulo P – Estilos de Vida: P30a até P35a (BD – PNS)
Dimensão: Condições físicas e mentais		
Doenças associadas: Hipertensão arterial, diabetes mellitus e dislipidemias são as doenças crônicas mais fortemente associadas ao risco de AVC, sendo reconhecidas como fatores primários de risco cardiovascular (Feigin et al., 2016).	- Presença de hipertensão arterial - Presença de diabetes mellitus - Presença de dislipidemia (colesterol elevado)	Módulo Q – Doenças Crônicas: Q30a, Q32a, Q38a (BD – PNS)
Doenças pós AVC: O AVC pode gerar complicações físicas e funcionais, como sequelas motoras, dificuldades de fala, perda de memória e maior risco de novos eventos cerebrovasculares (Mohan et al., 2011).	- Presença de limitações funcionais após AVC - Dificuldades motoras e de locomoção - Problemas de fala e cognição	- Módulo G – Pessoas com Deficiência (BD – PNS) - Módulo Q – Doenças Crônicas: Q47a (BD – PNS)

Saúde mental: Aspectos (conhecimento científico): Depressão, ansiedade e estresse estão associados a maior risco de AVC, além de impactarem a recuperação e reabilitação após o evento (Lee et al., 2020).	• Presença de sintomas depressivos • Presença de ansiedade • Autopercepção de saúde mental	• Módulo Q – Doenças Crônicas: Q33a (BD – PNS) • Módulo P – Estilos de Vida: questões sobre percepção de saúde (BD – PNS)
Dimensão: Condições socioeconômicas		
Plano de saúde: Aspectos (conhecimento científico): A posse de plano de saúde está associada a maior acesso a consultas, exames preventivos e acompanhamento clínico, reduzindo desigualdades no cuidado do AVC (Barata et al., 2019).	• Presença ou ausência de plano de saúde • Tipo de plano de saúde (individual, familiar, empresarial) • Utilização efetiva do plano	• Módulo J – Utilização de Serviços de Saúde (BD – PNS) • Questões específicas sobre cobertura de plano de saúde (BD - Pns)
Renda domiciliar: Aspectos (conhecimento científico): Baixa renda está associada a maior vulnerabilidade social e menor acesso a medidas de prevenção do AVC, como alimentação saudável e serviços de saúde de qualidade (Bird, 2015).	• Renda domiciliar mensal • Renda per capita • Fontes de rendimento (trabalho, aposentadoria, benefícios sociais)	• Módulo F – Rendimentos (BD – PNS)
Trabalho: Aspectos (conhecimento científico): Condições de trabalho (tipo de ocupação, jornada, exposição a estresse) influenciam diretamente na saúde	• Situação de ocupação (empregado, desempregado, informal) • Jornada de trabalho semanal • Condições de trabalho (exposição a riscos, esforço físico, estresse)	• Módulo E – Características do trabalho (BD – PNS)

cardiovascular e no risco de AVC (Kivimäki & Steptoe, 2018).		
Dimensão: Características do indivíduo		
Sexo e idade: Sexo e idade são fatores individuais diretamente ligados ao risco de AVC (Gale & Gillespie, 2001).	- Sexo - Idade	Módulo C – Características gerais dos moradores (BD - PNS)
Dimensão: Genética /histórico familiar		
Doenças crônicas familiar: Predisposição individual e histórico familiar de doenças crônicas aumentam a probabilidade de desenvolver AVC (Ali, 2013)	- Recomendação médica - por histórico familiar - Tipo de predisposição - Severidade	Módulo Q – Doenças Crônicas: Q46a (BD – PNS)
Dimensão: Registros corporais		
Peso altura e IMC: Peso e altura utilizados para calcular o IMC e avaliar risco de obesidade, fator ligado ao desenvolvimento de doenças cardiovasculares (Leong & Wilding, 1999).	- Peso - Altura - IMC - Nível de gordura corporal	Módulo W– Antropometria: P1a, P4a, W000201, W000202 (BD – PNS)

Fonte: <https://www.pns.iciet.fiocruz.br/>.

2.3 DESCRIÇÃO DA BASE DE DADOS APÓS O PRÉ-PROCESSAMENTO

A base de dados atual é um conjunto de dados estruturado com 24.536 instâncias, sendo na coluna “Target”, “Tem AVC?” números de 1 a 2, 1 para pessoas que possuem a doença, 1.054 e 2 para pessoas que não possuem a doença, 23.482, tendo

25 atributos. Do ponto de vista mais técnico, todos os 25 atributos estão armazenados como numéricos.

Uma característica crucial desta versão processada é a eliminação completa das ambiguidades e falhas mencionadas no texto original. Diferentemente da base bruta, não há presença de valores ausentes (nulos) em nenhuma das colunas, e o uso de códigos de controle (como o antigo valor 9 para "não se aplica") foi tratado; na variável "Fumante atual?", por exemplo, restam apenas as categorias válidas 1, 2 e 3, tornando o conjunto de dados "limpo" e pronto para aplicação imediata de modelos estatísticos.

Tabela 2- Dimensões pós processamento

Descrição do Mapa Conceitual - Após o pós processamento			
Dimensão	Aspecto	Códigos	Novas colunas
Antropologia	Características físicas	C006, C008, C009	—
	Altura e peso	W00103, W00203	IMC
Saúde	Plano de saúde	I00102	—
	Práticas de esportes	P034, P03702	—
	Doenças relacionadas	Q00201, Q03001, Q060, Q06306, Q092, Q11006	—
Trabalho	Jornada de trabalho	P039, P03906	—
Consumo	Consumo de sal	P02601	—
	Consumo de álcool	P027	—
	Alimentos saudáveis	P006, P00901, P018, P01601	—
	Alimentos tipo proteínas	P01101, P013, P015	Consumo de carne
	Consumo	P050	—
AVC	Doença associada	Q068	—

Fonte: <https://www.pns.iciet.fiocruz.br/>.

3. PRÉ PROCESSAMENTO DA BASE DE DADOS


3.1 IDENTIFICAÇÃO DA IDADE POR MEIO DE FREQUÊNCIA ACUMULADA

Para iniciarmos nosso trabalho precisaremos primeiro identificar a idade alvo das pessoas com AVC. Para que isso aconteça, precisamos fazer o cálculo da frequência acumulada da coluna “Idade do entrevistado”.

Após o cálculo, conseguimos concluir que, a idade que mais possuem pessoas com AVC é as pessoas de 55 a 77 anos. Esse cálculo é feito da seguinte forma: A frequência relativa percentual foi calculada através da razão entre a frequência absoluta de cada

categoria específica (n) e o tamanho total da amostra válida (N), sendo o quociente resultante multiplicado por 100. Esta operação converte a contagem bruta numa proporção padronizada, permitindo mensurar a representatividade de cada subgrupo, como a prevalência de uma comorbilidade ou categoria sociodemográfica, em relação à totalidade da população estudada.

Imagem 2 – Frequência Acumulada da coluna “Idade do entrevistado”.



Fonte: Autoria própria.

3.2 REMOÇÃO DE OUTLIERS

A remoção de Outliers é uma parte muito importante no nosso tratamento na base de dados. Usamos então o método IQR (Intervalo Interquartil), usamos o conceito matemático, “regra do 1.5”. O código não sai deletando números aleatoriamente, ele define o que é “normal”, baseando-se na concentração dos dados em nossa base. Após a execução dos códigos, foram eliminados 602 linhas.


1 – Q1(Quartil 25%): O código separa os menores 25% valores

2 – Q2(Quartil 75%): O código separa os menores 75% valores, ou seja, onde começa os 25% maiores valores.

3 – IQR: É a diferença entre o Q3 – Q1, representa onde está a maioria, ou seja, 50% das pessoas “normais” da nossa base.

O código cria dois limites usando o fator 1.5, o padrão estatístico. Sendo o limite inferior: $Q1 - (1.5 * IQR)$. E o limite superior: $Q3 + (1.5 * IQR)$. Qualquer valor que esteja abaixo do piso, ou acima do teto é considerado um Outlier e é marcado para a exclusão.

Imagem 3 – Antes e depois com a remoção de Outlier.




Fonte: Autoria própria.

3.3 IMPUTAÇÃO DE DADOS AUSENTES

Após a longa remoção dos outliers, temos que fazer a remoção dos dados ausentes por meio do MissForest, ou por meio do KNN Imputer. Após alguns testes, pudemos perceber que o melhor meio de imputação foi o MissForest, enquanto o KNN apresentou um erro médio de 11,16, o MissForest reduziu esse erro para 4,17. Com tudo isso, conseguimos entender que teve uma melhoria de 62,6% de acuraria. Isso indica que, dada a estrutura multivariada e não-linear dos dados de saúde coletados, a abordagem baseada em árvores de decisão (Random Forest) consegue reconstruir os perfis dos pacientes com significativamente mais fidelidade do que os métodos baseados em distância euclidiana.

Imagem 4 – Comparação entre Imputadores.



Fonte: Autoria própria.

3.4 COMBINAÇÃO ENTRE ATRIBUTOS

Após a seleção das colunas chave e da remoção de colunas inconsistentes para nossa análise, precisaremos realizar algumas junções entre atributos.

“Quantos dias come proteínas?”: Para diminuirmos os atributos de alimentação, precisávamos juntar outras três colunas que remetessem proteínas, são elas: “Quantos dias come carne vermelha”, “Quantos dias comem peixe?” e “Quantos dias comem frango?”. Mantivemos as mesmas métricas, sendo de 1 a 7, comem todos os dias na semana, por exemplo e 0, não come nenhum dia da semana. Favor olhar a tabela 2.

Para fazermos as métricas, usamos a soma agregada, realizando o somatório direto dos valores de frequência das três colunas para cada indivíduo, representando o número total de dias de consumo de proteína. Após isso, demos o contexto da frequência dietética que é o número de dias em uma semana, o resultado da soma agregada foi limitado (capped) a um valor máximo de 7. Assim, qualquer soma resultante maior que 7 foi definida como 7, enquanto somas menores ou iguais a 7 mantiveram seu valor original.

“IMC”: Usamos uma técnica mais fácil para o cálculo do Índice de Massa Corporal, como já tínhamos todos os dados já preenchidos, apenas passamos os dados de altura, que eram em centímetros, para metros. Com isso, fizemos o cálculo base do IMC, que é peso em quilo gramas por altura em metros ao quadrado. As métricas que usamos seguem as mesmas da OMS (Organização Mundial da Saúde).

$$\text{IMC} = \frac{\text{peso}}{\text{altura}^2}$$

Se $IMC < 18.5$: ‘Abaixo do peso’

Se $30 \leq IMC < 34.99$: ‘Obesidade grau I’

Se $18.5 \leq IMC < 24.99$: ‘Peso normal’

Se $35 \leq IMC < 39.99$: ‘Obesidade grau II’

Se $25 \leq IMC < 29.99$: ‘Sobrepeso’

Se $IMC \geq 40$: ‘Obesidade grau III’

3.5 REMOÇÃO DE DADOS INCONSISTENTES E REDUNDANTES

Após o processo de imputação, o conjunto de dados foi submetido a uma rigorosa rotina de limpeza e validação para assegurar a consistência interna e a plausibilidade biológica da amostra, removendo apenas 5 linhas, consolidando 24541 linhas finais. Subsequentemente, foram aplicados filtros lógicos de exclusão para remover valores incongruentes ou decorrentes de erro de medição, restringindo a análise a intervalos fisiologicamente e temporalmente possíveis: idade compreendida entre 18 e 100 anos, Índice de Massa Corporal (IMC) situado entre 10 e 100 kg/m², bem como a remoção de valores negativos ou que excedessem o limite físico semanal (168 horas) nas variáveis.

3.6 DIVISÃO TRAIN TEST SPLIT

Inicialmente tivemos que marcar a coluna “Target” da nossa base de dados, ela sendo a coluna: “Tem AVC?”. Após isso conseguimos separar a base de dados em duas novas bases, sendo uma 30% da original para o teste e a outra sendo 70% da base, sendo ela para o treino. Com tudo isso, conseguimos fazer a progressão de nosso trabalho.

4. BALANCEAMENTO E RESULTADOS

4.1 BALANCEAMENTO DA BASE DE DADOS TREINO

Para tentar resolver o grande desequilíbrio de classes em nossa base de dados, adotou-se uma estratégia híbrida. Sendo assim, adotamos um modelo de subamostragem seletiva, conhecida como (Intelligent Downsampling) da classe majoritária, após isso, usamos mais uma tática de balanceamento, aplicamos o SMOTE (Synthetic Minority Over-sampling Technique) à classe minoritária, que gera dados sintéticos através da interpolação linear entre os vizinhos próximos.

Com tudo isso, pudemos perceber que houve um enriquecimento dos dados das pessoas que tem AVC, aumentando bastante nossa classe minoritária. Tentamos outros

tipos de balanceamentos, mas o único que resolveu o problema foi o SMOTE, conseguindo aumentar o recall e a precisão desta classe (Com AVC).

4.2 BALANCEAMENTO DA BASE DE DADOS TESTE

Após muitos testes com os hiper parâmetros, tivemos muita dificuldade em aumentar a precisão da classe minoritária, com isso, após muita pesquisa, tivemos uma ideia de balancear os dados da base teste, já que ela tinha muita pouca pessoa com AVC. Deixamos o número total na minoritária e na majoritária pegamos entre 60 a 70 por cento do total da minoritária. Tínhamos 707 pessoas com AVC e 15732 pessoas sem AVC.


Assim, conseguimos aumentar bastante a precisão de nossos testes dos hiper parâmetros.

4.3 ANÁLISE DOS RESULTADOS

- **Árvore de Decisão (Decision Tree):** O modelo de Árvore de Decisão apresentou o desempenho mais modesto entre os classificadores avaliados, com uma acurácia global de 60,76% e uma AUC-ROC de 0,5480, valor próximo ao aleatório (0,50). Embora tenha alcançado um Recall de 25,00% para a classe positiva (AVC), a sua baixa capacidade de discriminação geral sugere que as regras rígidas criadas durante o treino não generalizaram bem para os dados de teste, indicando instabilidade na separação das classes num cenário mais equilibrado.
- **K-Nearest Neighbors (KNN):** O algoritmo KNN destacou-se por apresentar a maior sensibilidade (Recall) para a classe de interesse, identificando corretamente 32,91% dos casos positivos de AVC. Com uma acurácia global de 64,18% e AUC de 0,6487, o KNN provou ser o método mais eficaz para minimizar os falsos negativos (pacientes doentes não diagnosticados) entre os modelos clássicos do Scikit-Learn. Este comportamento sugere que a estratégia baseada na vizinhança local foi eficiente para capturar grupos de risco na estrutura dos dados.

- Random Forest: O Random Forest demonstrou um comportamento conservador e altamente específico. Embora tenha registado a maior AUC global (0,7180) e a maior Precisão para a classe AVC (67,57%), indicando que, quando prevê um AVC, tem alta probabilidade de estar certo, o modelo falhou na tarefa de rastreio, apresentando o pior Recall do experimento (15,82%). O algoritmo priorizou excessivamente a classe maioritária (Recall de 0: 94,94%), tornando-o robusto contra falsos positivos, mas pouco útil para a deteção primária de casos em risco. A imagem a seguir é os ramos do Random Forest.

Imagem 5 – Ramos do Random Forest.



Fonte: Autoria própria.

- Multilayer Perceptron (MLP - Scikit-Learn): A rede neural implementada via Scikit-Learn obteve resultados intermediários, com acurácia de 62,15% e AUC de 0,6621. O seu desempenho na classe positiva (Recall de 19,62%) foi inferior ao do KNN e do KerasMLP, indicando dificuldades em convergir para uma solução ótima com a arquitetura padrão ou limitações na otimização dos pesos frente ao desbalanceamento, comportando-se de forma semelhante ao Random Forest, mas com menor precisão.


- Keras MLP (Deep Learning): A implementação da Rede Neural via Keras (KerasMLP) apresentou o melhor equilíbrio global do estudo. O modelo alcançou a maior acurácia global (65,32%) e uma AUC competitiva de 0,7058. Diferente do Random Forest, o KerasMLP conseguiu balancear melhor a relação entre Precisão (65,91%) e Recall (27,53%), oferecendo uma solução robusta que mantém uma boa taxa de detecção de verdadeiros positivos sem elevar drasticamente a taxa de falsos alarmes, validando o uso de arquiteturas de Deep Learning personalizadas para este tipo de problema.

Tabela 3 – Resultados dos hiper parâmetros.

Resultados								
	Global_Accuracy	Global_AUC	Recall tem AVC	Precision tem AVC	F1 tem AVC	Recall Não tem AVC	Precision Não tem AVC	F1 Não tem AVC
DecisionTree	0,6	0,54	0,25	0,51	0,33	0,84	0,62	0,72
KNN	0,64	0,64	0,32	0,59	0,42	0,85	0,65	0,74
RandomForest	0,63	0,71	0,15	0,67	0,25	0,94	0,62	0,75
MLP	0,62	0,66	0,19	0,57	0,29	0,9	0,62	0,74
KerasMLP	0,65	0,7	0,27	0,65	0,38	0,9	0,65	0,75

Fonte: Autoria própria.

Imagem 6 – Resultados dos hiper parâmetros em gráfico.



Fonte: Autoria própria.

4.4 RESULTADOS DAS REGRAS DE AVC

A imagem 7, apresenta quatro combinações principais de fatores de risco que levam ao Acidente Vascular Cerebral (AVC), destacando a hipertensão como o elemento mais crítico, presente em três das quatro regras. Essas regras evidenciam que o risco é

geralmente cumulativo, associando condições clínicas a hábitos de vida pouco saudáveis, como o tabagismo, o consumo excessivo de álcool, a baixa ingestão de frutas e o sedentarismo, além de fatores externos como jornadas de trabalho pesadas.

Interessante notar que os perfis variam significativamente: enquanto as Regras 1 e 2 mostram que pessoas sem depressão, mas hipertensas e com rotinas desgastantes (fumo ou trabalho pesado), estão em risco, as Regras 3 e 4 abordam cenários diferentes. A Regra 3 foca em quem possui depressão aliada ao sedentarismo e álcool, e a Regra 4 alerta que, mesmo sem hipertensão, quem possui problemas cardíacos e fuma frequentemente (mais de 3 vezes ao dia) também possui alta probabilidade de sofrer um AVC.

Imagem 7 – Regras de risco para ter AVC.



Fonte: Imagem gerada por IA, por meio dos dados obtidos.

5. CONCLUSÃO

Após tudo isso, podemos concluir que o trabalho atingiu seu objetivo de utilizar Machine Learning para caracterizar o perfil do adulto brasileiro com risco de AVC, utilizando a base robusta da PNS 2019. A literatura já indicava fatores de risco isolados, mas o nosso estudo, através das regras geradas, conseguiu mostrar como esses fatores se comportam de forma cumulativa na população brasileira. Infelizmente, a análise dos dados revela um cenário preocupante sobre como o doente brasileiro está se tratando: percebemos que muita gente não está comendo

bem, com baixa ingestão de frutas, além de manter hábitos nocivos como o alto consumo de álcool e o sedentarismo. Além disso, o estilo de vida moderno, com jornadas de trabalho pesadas somadas à hipertensão e depressão, cria um "combo" perigoso que aumenta drasticamente as chances da doença.

O potencial deste trabalho é muito grande, especialmente se pensarmos em uma aplicação direta para os planos de saúde. Com os modelos que treinamos e as regras que descobrimos, as operadoras poderiam criar sistemas de alerta preventivo. Por exemplo, ao identificar segurados que se encaixam na "Regra 4" (problema cardíaco e fumo frequente, mesmo sem hipertensão), o plano poderia intervir antes que o AVC aconteça. Isso não só ajudaria a salvar vidas, mas também reduziria custos com internações complexas. Para o futuro, o que podemos fazer com o projeto é tentar transformá-lo em uma ferramenta prática, talvez uma API ou aplicativo, pois o "grande processo" de pré-processamento e a otimização dos hiper parâmetros deixaram a base limpa e os modelos prontos para serem usados em diagnósticos reais.

REFERÊNCIAS

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). Pesquisa Nacional de Saúde 2019: percepção do estado de saúde, estilos de vida, doenças crônicas e saúde bucal. Rio de Janeiro: IBGE, 2020. Disponível em: <https://www.pns.icict.fiocruz.br/>. Acesso em: 20 nov. 2024.

SOCIEDADE BRASILEIRA DE DOENÇAS CEREBROVASCULARES (SBAVC). Números do AVC no Brasil. 2024. Disponível em: <http://www.sbavc.org.br>. Acesso em: 20 nov. 2024.

WORLD HEALTH ORGANIZATION (WHO). WHO report on the global tobacco epidemic, 2017: monitoring tobacco use and prevention policies. Geneva: World Health Organization, 2017.

2. Referencial Teórico: Saúde, AVC e Fatores de Risco (Autores citados no texto)
ALI, K. et al. Stroke, genetics, and the family history. *Stroke*, v. 44, n. 6, p. 20-25, 2013.

BARATA, R. B. et al. Desigualdades sociais no acesso e uso de serviços de saúde no Brasil. *Ciência & Saúde Coletiva*, v. 24, p. 881-888, 2019.

BIRD, C. E. et al. Socioeconomic status, exposure to risk factors, and stroke. *Stroke*, v. 46, n. 5, p. 121-126, 2015.

FEIGIN, V. L. et al. Global burden of stroke and risk factors in 188 countries, during 1990–2013: a systematic analysis for the Global Burden of Disease Study 2013. *The Lancet Neurology*, v. 15, n. 9, p. 913-924, 2016.

GALE, C. R.; GILLESPIE, C. Sex and age differences in the incidence of stroke. *Journal of Epidemiology & Community Health*, v. 55, n. 1, p. 16-22, 2001.

KIVIMÄKI, M.; STEPTOE, A. Effects of stress on the development and progression of cardiovascular disease. *Nature Reviews Cardiology*, v. 15, n. 4, p. 215-229, 2018.

LAMONTE, M. J. et al. Physical activity and diabetes prevention. *Journal of Applied Physiology*, v. 99, n. 3, p. 1205-1213, 2005.

LEE, H. Y. et al. Depression and Risk of Stroke in the Elderly Population. *Journal of Geriatric Psychiatry and Neurology*, v. 33, n. 1, p. 34-41, 2020.

LEONG, K. S.; WILDING, J. P. Obesity and diabetes. *Best Practice & Research Clinical Endocrinology & Metabolism*, v. 13, n. 2, p. 221-237, 1999.

MALIK, V. S. et al. Sugar-sweetened beverages and risk of metabolic syndrome and type 2 diabetes: a meta-analysis. *Diabetes Care*, v. 33, n. 11, p. 2477-2483, 2010.

MOHAN, K. M. et al. Risk of recurrent stroke after the first ever stroke: a systematic review and meta-analysis. *International Journal of Stroke*, v. 6, p. 1-13, 2011.

3. Referencial Técnico: Machine Learning e Algoritmos (Usados no seu código)
BREIMAN, Leo. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5-32, 2001.

CHAWLA, N. V. et al. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, v. 16, p. 321-357, 2002.

CHOLLET, François et al. Keras. GitHub. Disponível em:
<https://github.com/fchollet/keras>. Acesso em: 2024.

FACELI, Katti et al. Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina. 2. ed. Rio de Janeiro: LTC, 2021.

HINTON, G.; SALAKHUTDINOV, R. Reducing the dimensionality of data with neural networks. *Science*, v. 313, n. 5786, p. 504-507, 2006.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

STEKHOVEN, D. J.; BÜHLMANN, P. MissForest—non-parametric missing value imputation for mixed-type data. *Bioinformatics*, v. 28, n. 1, p. 112-118, 2012.

VAN DER MAATEN, L.; HINTON, G. Visualizing data using t-SNE. *Journal of Machine Learning Research*, v. 9, p. 2579-2605, 2008.