

Nome: _____

Data: 24/06/2025

1. Esta avaliação vale 30 pontos
2. É individual e SEM consulta
3. A interpretação faz parte da avaliação

Questão 01 (5 pontos)

Considere que em um determinado supermercado foram efetuadas as seguintes transações:

1		Detergente	Limão		Feijao
2	Alcool	Detergente	Limão		
3	Alcool			Arroz	
4			Limão		
5		Detergente	Limão	Arroz	
6	Alcool			Arroz	Feijao
7	Alcool	Detergente	Limão	Arroz	Feijao

Utilizando-se o algoritmo Apriori, um suporte mínimo aceitável de **0.3** e confiança de **0.6**, o número de regras geradas a partir desta base de dados é de:

- a) 1
- b) 2
- c) 3
- d) 4
- e) 5

Importante: 1) Você deve apresentar a solução da questão na prova. Ou seja, resposta sem a apresentação da solução não será considerada; 2) Coloque aqui a(s) regra(s), juntamente com a confiança e o Lift

Regra	Confiança	Lift

Questão 02 (1,5 pontos)

Na área de mineração de dados, uma das formas de se obter conhecimento é por meio das Regras de Associação, que buscam eventuais associações entre 2 determinados produtos, um denominado antecedente e o outro, consequente.

Uma medida utilizada nesse tipo de regra é denominada '**suporte**', que representa:

- A) a fração da população-alvo que satisfaz o antecedente e o consequente.
- B) a razão entre o produto antecedente e o consequente
- C) a razão entre o produto consequente e o precedente.
- D) o número absoluto da população-alvo que satisfaz o antecedente e o consequente
- E) o número absoluto de produtos do tipo antecedente.

Questão 03 (1,5 pontos)

Com relação às características e limitações do KNN, considere as afirmações a seguir:

- I. O KNN é sensível a atributos com escalas diferentes, por isso é recomendada a normalização dos dados.
- II. O KNN tende a se sair melhor em bases de dados de alta dimensionalidade, devido à maior riqueza de atributos.
- III. O valor de k influencia diretamente a performance do modelo, podendo afetar o viés e a variância.

Assinale a alternativa correta:

- a) Apenas I
- b) Apenas II
- c) Apenas I e III
- d) Apenas II e III
- e) I, II e III

Questão 04 (1,5 pontos)

Sobre o funcionamento do algoritmo KNN, analise as afirmativas abaixo:

- I. O KNN é um algoritmo supervisionado que classifica uma nova instância com base nas classes dos seus vizinhos mais próximos.
- II. O KNN realiza um processo de treinamento complexo e lento, enquanto a fase de classificação é extremamente rápida.
- III. A escolha da métrica de distância, como a Euclidiana ou Manhattan, pode afetar diretamente o desempenho do KNN.

Assinale a alternativa correta:

- a) Apenas I
- b) Apenas I e II
- c) Apenas I e III
- d) Apenas II e III
- e) I, II e III

Questão 05 (1,5 pontos)

Observe as propriedades a seguir.

- I. Algoritmo de Aprendizado Indutivo como parte integrada do método.
- II. Uso do ganho de informação como critério de decisão ao ponderar sobre a escolha de atributos.
- III. Algoritmo resolve problemas de classificação numérica.

Assinale a alternativa que apresenta o algoritmo que reúne **todas as propriedades** listadas acima:

- a) ID3
- b) C45
- c) A-Priori
- d) K-means
- e) Random Forest

Questão 06 (1,5 pontos)

A respeito do algoritmo **Random Forest**, avalie as afirmações abaixo:

- I. Ele resolve problemas de classificação nominal e numérica
- II. Ele trabalha com atributos nominais e numéricos
- III. Ele utiliza o método de amostragem cross-validation para geração das árvores

É **correto** o que se afirma em:

- a) I, apenas.
- b) II, apenas.
- c) I e II, apenas.
- d) II e III, apenas.
- e) I, II e III.

Questão 07 (1,5 pontos)

A respeito do algoritmo de árvore de decisão **C45**, avalie as afirmações abaixo:

- I. Ele não trabalha com dados ausentes
- II. Ele resolve problemas de regressão
- III. Ele tem o mecanismo de poda que ajuda a reduzir o tamanho da árvore, aumentando a sua interpretabilidade

É **correto** o que se afirma em:

- a) I, apenas.
- b) III, apenas.
- c) I e II, apenas.
- d) II e III, apenas.
- e) I, II e III.

Questão 08 (1,5 pontos)

Considere as seguintes afirmações sobre aprendizado multi-label:

- I. Em aprendizado multi-label, uma instância pode pertencer a várias classes simultaneamente, diferentemente do aprendizado de classificação multi-classe.
- II. A abordagem Binary Relevance transforma um problema multi-label em vários problemas binários

independentes.

III. Algoritmos como Random Forest não podem ser usados diretamente para resolver problemas multi-label.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.

Questão 09 (1,5 pontos)

Sobre as aplicações práticas de aprendizado multi-label, analise as seguintes afirmações:

- I. Sistemas de recomendação podem usar aprendizado multi-label para sugerir múltiplos itens simultaneamente.
- II. Classificação de imagens multi-rótulo, como identificar objetos em uma imagem, é um exemplo típico de aprendizado multi-label.
- III. O aprendizado multi-label não é adequado para tarefas de categorização de texto.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.

Questão 10 (1,5 pontos)

Considere as seguintes afirmações sobre a métrica **Hamming Loss** no contexto de aprendizado multi-label:

- I. A Hamming Loss é sensível ao desbalanceamento entre classes, penalizando mais fortemente rótulos majoritários.
- II. A Hamming Loss mede a proporção de rótulos incorretamente previstos em relação ao número total de rótulos.
- III. Uma Hamming Loss de 0 indica que todos os rótulos foram previstos corretamente para todas as instâncias.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.

Questão 11 (2 pontos)

Considere o seguinte conjunto de previsões de um modelo multi-label para 3 instâncias:

- **Instância 1:** Verdadeiro: [1,0,1]; Previsto: [1,1,0]
- **Instância 2:** Verdadeiro: [0,1,0]; Previsto: [0,1,0]
- **Instância 3:** Verdadeiro: [1,1,1]; Previsto: [1,0,1]

Sobre o cálculo da **Hamming Loss** para essas previsões, analise as seguintes afirmações:

- I. A Hamming Loss para a primeira instância é $2/3$.
- II. A Hamming Loss total do modelo é a média das Hamming Loss individuais das instâncias.
- III. A Hamming Loss total para esse conjunto de dados é 0.222.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.

Questão 12 (2 pontos)

Sobre a interpretação da **Hamming Loss**, analise as seguintes afirmações:

- I. Um valor de Hamming Loss próximo de 1 indica um modelo que frequentemente erra na predição de rótulos.
- II. Em problemas desbalanceados, a Hamming Loss pode mascarar erros em rótulos minoritários.
- III. Uma Hamming Loss de 0.2 significa que 20% dos rótulos totais foram previstos incorretamente.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.

Questão 13 (1 pontos)

Considere as seguintes afirmações sobre o conceito de AutoML:

- I. O AutoML automatiza etapas do pipeline de aprendizado de máquina, como seleção de algoritmos, ajuste de hiperparâmetros e pré-processamento.
- II. O AutoML é projetado para resolver qualquer tipo de problema, independentemente dos recursos computacionais disponíveis.
- III. Ferramentas de AutoML podem superar especialistas humanos ao eliminar a necessidade de conhecimento técnico profundo.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.

Questão 14 (1 pontos)

Considere as limitações do AutoML em comparação com pipelines manuais:

- I. O AutoML é ideal para tarefas com poucos dados rotulados, pois elimina a necessidade de modelos pré-treinados.

- II. Ferramentas de AutoML podem ser limitadas ao conjunto de algoritmos disponíveis em sua implementação.
- III. O AutoML pode produzir soluções subótimas em problemas complexos que requerem ajustes especializados.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.

Questão 15 (1 pontos)

Sobre as vantagens e desvantagens do AutoML, analise as seguintes afirmações:

- I. O AutoML facilita a implementação de aprendizado de máquina por não especialistas, mas pode ser mais lento devido ao grande número de combinações avaliadas.
- II. Soluções de AutoML geralmente sacrificam interpretabilidade em favor de modelos complexos e altamente ajustados.
- III. O AutoML é sempre mais eficiente que pipelines criados manualmente, independentemente do contexto.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.

Questão 16 (1,5 pontos)

Sobre os hiperparâmetros do Random Forest, analise as seguintes afirmações:

- I. O Random Forest é robusto a overfitting, independentemente dos valores escolhidos para os hiperparâmetros.
- II. O número de árvores ($n_estimators$) deve ser ajustado para um valor alto o suficiente para reduzir a variância do modelo, mas sem aumentar excessivamente o custo computacional.
- III. O número máximo de características ($max_features$) define o tamanho do subconjunto de recursos a ser considerado em cada divisão, afetando o viés e a variância.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.

Questão 17 (1,5 pontos)

Considere as seguintes afirmações sobre etapas de normalização e padronização no pré-processamento de dados:

- I. A normalização escala os valores para um intervalo definido, geralmente entre 0 e 1.
- II. A padronização transforma os dados para que tenham média 0 e desvio padrão 1, sendo mais adequada para modelos baseados em distância.

III. Ambos os métodos são adequados para conjuntos de dados com outliers extremos, pois não são afetados por valores discrepantes.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.

Questão 18 (1,5 pontos)

Sobre o tratamento de valores ausentes no pré-processamento, analise as seguintes afirmações:

- I. A imputação de valores ausentes pode ser realizada utilizando medidas como média, mediana ou moda, dependendo do tipo de dado.
- II. A exclusão de linhas ou colunas com valores ausentes é sempre a melhor abordagem, especialmente em conjuntos de dados grandes.
- III. Métodos avançados, como imputação por KNN, podem preservar melhor a estrutura dos dados ao lidar com valores ausentes.

É **correto** o que se afirma em:

- a) Apenas I está correta.
- b) Apenas I e II estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II e III estão corretas.
- e) Todas estão corretas.