

# Análise dos Determinantes da Asma no Brasil: PNS 2019 com Foco em Alimentação, Atividade Física e Modelos Interpretáveis

Isaque Gomes Azevedo  
Pontifícia Universidade Católica de  
Minas Gerais (PUC Minas)  
Belo Horizonte, MG, Brasil  
isaquegomes623@gmail.com

Luis Enrique Zarate Galvez\*  
Pontifícia Universidade Católica de  
Minas Gerais  
Brasil

Cristiane Neri Nobre†  
Pontifícia Universidade Católica de  
Minas Gerais  
Brasil

## Resumo

This paper analyzes microdata from the 2019 National Health Survey (PNS) to estimate the prevalence of self-reported asthma in Brazilian adults and to explore how social, behavioral, and specifically dietary factors relate to this outcome. By combining descriptive statistics with machine learning models—ranging from interpretable Decision Trees to Multilayer Perceptrons (MLP) and Keras-based neural networks—we investigate the predictive power of lifestyle variables. The results highlight a decision logic where the absence of recent physical activity, combined with high consumption of ultra-processed foods, delineates a specific risk profile. Furthermore, the comparative analysis reveals that optimizing neural architectures (KerasMLP) significantly reduces false negatives compared to standard implementations, offering superior sensitivity for public health screening.

**Resumo.** Este artigo analisa microdados da Pesquisa Nacional de Saúde (PNS) 2019 para estimar a prevalência autorreferida de asma em adultos e avaliar como fatores sociais, de estilo de vida e, principalmente, alimentares se relacionam com esse desfecho. Combinando estatística descritiva e modelos de Machine Learning — desde Árvores de Decisão interpretáveis até Perceptrons Multicamadas (MLP) e redes via Keras —, investiga-se o poder preditivo de variáveis de hábito. Os resultados destacam uma lógica de decisão onde a ausência de atividade física recente, combinada ao alto consumo de alimentos ultraprocessados, delinea um perfil de risco específico. Além disso, a análise comparativa revela que a otimização de arquiteturas neurais (KerasMLP) reduz significativamente os falsos negativos em comparação a implementações padrão, oferecendo sensibilidade superior para triagem em saúde pública.

## CCS Concepts

• **Computing methodologies** → **Machine learning**; • **Applied computing** → *Health informatics*.

## Keywords

Asma, PNS 2019, alimentos ultraprocessados, atividade física, determinantes sociais, Machine Learning, Deep Learning

## 1 Introdução

A asma é uma doença inflamatória crônica das vias aéreas caracterizada por hiperresponsividade brônquica e obstrução variável ao fluxo aéreo. No Brasil, representa um dos agravos respiratórios

mais prevalentes, gerando impacto substancial no Sistema Único de Saúde (SUS) devido a internações recorrentes e custos com medicação contínua. Apesar dos avanços farmacológicos, o controle da doença permanece um desafio, sugerindo que determinantes não biológicos desempenham papéis cruciais na sua manifestação e gravidade.

Tradicionalmente, os estudos epidemiológicos focam em fatores ambientais clássicos, como exposição a alérgenos, poluição e histórico familiar. No entanto, a transição nutricional e epidemiológica vivenciada pelo Brasil nas últimas décadas trouxe à tona novos fatores de risco: o sedentarismo e a mudança nos padrões alimentares. O aumento exponencial no consumo de alimentos ultraprocessados — formulações industriais ricas em energia, gorduras e aditivos, mas pobres em nutrientes — tem sido correlacionado a um estado inflamatório sistêmico, que pode, teoricamente, exacerbar condições respiratórias.

A Pesquisa Nacional de Saúde (PNS 2019) oferece um panorama abrangente dessas variáveis, permitindo cruzar dados clínicos autorreferidos com marcadores detalhados de estilo de vida. Contudo, a análise desses dados por métodos estatísticos tradicionais (como regressão logística) pode falhar em capturar interações complexas e não lineares entre as variáveis.

Neste contexto, o uso de algoritmos de Machine Learning (ML) surge como uma abordagem promissora. Modelos computacionais podem identificar padrões latentes em grandes volumes de dados (Big Data), estabelecendo regras de classificação que auxiliam na compreensão dos determinantes da doença. Este trabalho propõe não apenas predizer o diagnóstico de asma, mas utilizar a modelagem para fins de *interpretabilidade*, elucidando quais combinações de fatores sociais e comportamentais mais discriminam os pacientes asmáticos na população brasileira.

**Objetivos.** O objetivo principal é estimar a prevalência de asma na PNS 2019 e investigar sua associação com o consumo de ultraprocessados e atividade física através de técnicas de ML. Especificamente, buscamos: (1) Comparar o desempenho de diferentes arquiteturas (Árvores, Ensembles e Redes Neurais) em um cenário de dados desbalanceados; (2) Analisar o trade-off entre sensibilidade e especificidade para fins de triagem; e (3) Extrair regras de decisão interpretáveis que possam orientar políticas públicas na Atenção Primária.

\*Orientador

†Orientadora

## 2 Fundamentação Teórica

### 2.1 Determinantes Sociais e Ambientais da Asma

A asma é uma doença multifatorial. Embora a predisposição genética seja determinante, a expressão fenotípica depende da interação com o ambiente. Estudos recentes apontam que a urbanização acelerada e as condições de moradia (presença de mofo, ventilação inadequada) são vetores de risco significativos. No Brasil, a desigualdade social agrava esse cenário, onde populações de baixa renda estão mais expostas a fatores desencadeantes intra e extradomiciliares.

### 2.2 Transição Nutricional e Ultraprocessados

A classificação NOVA, desenvolvida pelo Núcleo de Pesquisas Epidemiológicas em Nutrição e Saúde da USP (NUPENS), categoriza os alimentos segundo a extensão e o propósito do seu processamento. Evidências acumulam-se sobre os efeitos deletérios dos alimentos ultraprocessados (grupo 4 da NOVA) na saúde metabólica. Mecanismos propostos incluem a alteração da microbiota intestinal e a promoção de estresse oxidativo, processos que podem influenciar a resposta imune pulmonar. A investigação da relação entre dieta "ocidentalizada" e asma é um campo emergente na epidemiologia nutricional.

### 2.3 Machine Learning em Saúde Pública

A aplicação de ML em saúde divide-se macroscopicamente em duas vertentes: auxílio diagnóstico (imagem, exames) e epidemiologia computacional. Na epidemiologia, o foco desloca-se da inferência causal pura para a predição e reconhecimento de padrões complexos. Algoritmos baseados em árvores (Decision Trees, Random Forests) são valorizados pela sua interpretabilidade, permitindo a visualização direta das regras de decisão. Por outro lado, Redes Neurais Artificiais (ANN) e Perceptrons Multicamadas (MLP) são capazes de modelar fronteiras de decisão altamente não lineares, frequentemente superando métodos clássicos em acurácia, embora operem muitas vezes como "caixas-pretas". O desafio atual reside em equilibrar essa performance preditiva com a necessidade de explicação clínica.

## 3 Metodologia

### 3.1 Fonte de Dados: PNS 2019

O estudo é transversal e utiliza microdados da Pesquisa Nacional de Saúde 2019, inquérito de base populacional conduzido pelo Instituto Brasileiro de Geografia e Estatística (IBGE). A PNS utiliza amostragem por conglomerados em três estágios: (1) Setores Censitários (UPAs), (2) Domicílios e (3) Moradores com 15 anos ou mais selecionados aleatoriamente. Para este estudo, foram considerados apenas os indivíduos selecionados para a entrevista individual, garantindo a disponibilidade dos módulos de estilo de vida e doenças crônicas.

### 3.2 Variáveis e Engenharia de Features

A Tabela 1 apresenta o mapeamento entre as perguntas originais da PNS e as variáveis utilizadas ou construídas para a modelagem.

**Tabela 1: Dicionário de Variáveis e Engenharia de Features.**

| Dimensão                                  | Variáveis (Código Original → Feature)                                                                                                                                                                                                                                          |
|-------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Sociodemográfico</b>                   | C006 (Sexo); C008 (Idade); C009 (Cor/Raça); V0026 (Situação Censitária: Urbano/Rural); A001 (Tipo de domicílio); A005010 (Abastecimento de água).                                                                                                                              |
| <b>Condições do Domicílio</b>             | A003010 (Material do telhado); A004010 (Material do piso); A02306 (Quantidade de cachorros no domicílio).                                                                                                                                                                      |
| <b>Estilo de Vida</b>                     | P034 (Prática de exercício físico nos últimos 3 meses); P050 (Fuma atualmente).                                                                                                                                                                                                |
| <b>Alimentação (Features Construídas)</b> | <i>Origem: Módulo P (Alimentação)</i><br><b>ULTRA_SCORE</b> : Escore aditivo de consumo de ultraprocessados (refrigerantes, embutidos, biscoitos, salgadinhos).<br><b>BALANCE_ALIMENTAR</b> : Indicador da proporção entre alimentos in natura e processados na dieta semanal. |
| <b>Desfecho (Alvo)</b>                    | Q074: Diagnóstico médico de asma (0 = Não, 1 = Sim).                                                                                                                                                                                                                           |

**3.2.1 Desfecho (Target).** A variável alvo foi construída a partir da pergunta Q074: "Algun médico já lhe deu o diagnóstico de asma (ou bronquite asmática)?" A resposta foi binarizada (0: Não, 1: Sim).

**3.2.2 Variáveis Preditoras.** As variáveis foram selecionadas com base na literatura e na análise de entropia preliminar, divididas em quatro blocos:

- **Sociodemográfico:** Inclui Sexo (C006), Idade (C008), Cor/Raça (C009), Escolaridade e Região Geográfica. A idade foi mantida como contínua para os modelos neurais e discretizada para visualizações.
- **Estilo de Vida:**
  - *Atividade Física:* Utilizou-se a variável P034 ("Nos últimos três meses, praticou algum tipo de exercício físico ou esporte?") como proxy de comportamento ativo recente.
  - *Tabagismo:* Uso atual ou pregresso de tabaco.
- **Alimentação (Score de Ultraprocessados):** Foi criado um indicador sintético, denominado ULTRA\_SCORE, baseado na frequência de consumo relatada de itens marcadores de alimentação não saudável (refrigerantes, sucos em caixa, biscoitos recheados, salgadinhos de pacote, embutidos). O score é aditivo, onde maiores valores indicam pior qualidade da dieta.
- **Contexto Domiciliar:** Variáveis sobre a estrutura física da residência, como material do piso (A004010) e cobertura (A003010), além da presença de animais domésticos (A02306 - quantidade de cachorros), serviram como proxies para nível socioeconômico e exposição a alérgenos.

### 3.3 Pré-processamento e Limpeza

A limpeza dos dados envolveu as seguintes etapas:

- (1) **Tratamento de Missing Values:** Variáveis com alto percentual de dados faltantes estruturais (ex: perguntas "pule se...")





Figura 1: Mapa conceitual dos determinantes da asma: interações entre fatores biológicos, sociais, ambientais e de estilo de vida considerados no estudo.

foram codificadas como categoria "Não se aplica". Dados faltantes aleatórios foram imputados pela moda (categóricas) ou mediana (numéricas).

- (2) **Remoção de Outliers:** Para a variável idade (C008), aplicouse o método do Intervalo Interquartil (IQR). Conforme ilustrado na Figura 2, o processo removeu valores extremos que poderiam distorcer o treinamento dos modelos sensíveis à distância.
- (3) **Codificação:** Variáveis categóricas nominais foram submetidas a *One-Hot Encoding*, enquanto variáveis ordinais foram mapeadas numericamente.
- (4) **Normalização:** Para algoritmos sensíveis à escala (KNN, MLP), as variáveis contínuas foram normalizadas via *Min-Max Scaler* para o intervalo  $[0, 1]$ .

**3.3.1 Estratégia de Balanceamento.** Dada a prevalência de asma (5%), o dataset apresenta forte desbalanceamento de classes, o que tende a enviesar os modelos para a classe majoritária (não asmáticos). Para mitigar isso durante o treinamento, aplicou-se a técnica de *ClusterCentroids* (Undersampling baseado em clusters). Diferente do undersampling aleatório, que descarta dados arbitrariamente, o *ClusterCentroids* substitui grupos de amostras da classe majoritária pelo centróide do cluster (K-Means), preservando a estrutura da informação enquanto reduz o tamanho da amostra majoritária.



**Figura 2: Remoção de outliers na variável Idade (C008) utilizando o método IQR.**

### 3.4 Configuração dos Modelos

Foram avaliados cinco algoritmos com diferentes viéses indutivos:

- (1) **Decision Tree (CART):** Configuradas com profundidade máxima limitada a 3 ou 5 para garantir a interpretabilidade e extração de regras visuais. Critério de divisão: Entropia.
- (2) **Random Forest:** Ensemble de 100 árvores para reduzir a variância e o risco de overfitting da árvore única.
- (3) **K-Nearest Neighbors (KNN):** Algoritmo baseado em instância, utilizando distância Euclidiana ( $k = 5$ ).

- (4) **MLP (Scikit-Learn)**: Perceptron Multicamadas padrão, com otimizador Adam e ativação ReLU.
- (5) **KerasMLP**: Uma arquitetura de rede neural profunda customizada utilizando a biblioteca TensorFlow/Keras. A arquitetura consiste em:
  - Camada de Entrada (Input Layer).
  - Camadas Ocultas Densas (128 e 64 neurônios) com ativação ReLU e regularização Dropout (0.3) para prevenir overfitting.
  - Camada de Saída com ativação Sigmoid para classificação binária.
  - Otimização com ajuste fino de *learning rate* e função de perda *Binary Crossentropy*.

### 3.5 Validação

Utilizou-se a estratégia de *Hold-out* com estratificação, separando 30% dos dados para teste ("Teste Justo"). É crucial notar que o balanceamento (ClusterCentroids) foi aplicado **apenas** no conjunto de treino. O conjunto de teste manteve a distribuição original (desbalanceada) para refletir o cenário real de aplicação.

## 4 Resultados

### 4.1 Caracterização da Amostra e Prevalência

A análise descritiva inicial confirmou uma prevalência de diagnóstico médico de asma em torno de 5,3% na população adulta analisada. A distribuição etária dos diagnósticos revela padrões importantes.

As Figuras 3 e 4 ilustram o comportamento da doença no recorte de adultos jovens (0 a 30 anos). Observa-se que a curva de frequência acumulada é mais íngreme nas primeiras décadas de vida, sugerindo que grande parte dos diagnósticos é estabelecida na infância ou adolescência e persiste na vida adulta.




Figura 3: Comparação demográfica entre grupos (Asmáticos vs Não Asmáticos) no recorte etário de até 30 anos.




Figura 4: Frequência acumulada de diagnósticos de asma por idade. A inclinação acentuada inicial indica diagnósticos precoces.

### 4.2 Poder Discriminativo das Variáveis (Entropia)

A análise de Ganho de Informação (baseada na entropia de Shannon) foi utilizada para rankear a importância das variáveis antes da modelagem. Conforme exibido na Figura 5, variáveis relacionadas ao contexto domiciliar (como material de cobertura e piso) e variáveis de estilo de vida (atividade física e consumo alimentar) apresentaram altos índices de entropia. Isso indica que essas features possuem capacidade significativa de separar as classes (asmáticos de não asmáticos) e justifica sua inclusão nos modelos preditivos.





Figura 5: Entropia das principais features selecionadas. Variáveis de infraestrutura domiciliar e hábitos mostram alta relevância informacional.

### 4.3 Avaliação de Desempenho dos Modelos


A comparação entre os algoritmos foi realizada no conjunto de teste estratificado. A Figura 6 apresenta as métricas globais (Acurácia, Precisão, Recall, F1-Score e AUC-ROC). Embora a acurácia global seja alta em todos os modelos (devido à classe majoritária ser "não asmático"), a métrica AUC (Área Sob a Curva ROC) revela a verdadeira capacidade de discriminação. Neste quesito, as redes neurais

(MLP e KerasMLP) superaram os métodos baseados em árvores e distância.



**Figura 6: Métricas globais de desempenho no conjunto de teste. O KerasMLP destaca-se na métrica AUC, indicando melhor separabilidade geral.**

**4.3.1 Estabilidade e Intervalo de Confiança.** A Figura 7 apresenta o F1-Score médio com intervalo de confiança de 95%. Observa-se que o **KerasMLP** atinge um patamar superior de desempenho ( $F1 \approx 0.81$ ), com um intervalo de confiança que não se sobrepõe aos modelos baseados em árvore (Random Forest e Decision Tree) ou distância (KNN). Isso indica uma diferença estatisticamente significativa na robustez do modelo neural customizado.



**Figura 7: F1-Score com Intervalo de Confiança (95%) no Teste Justo. O KerasMLP demonstra superioridade estatística.**

#### 4.4 Análise Detalhada por Classe

Para aplicações médicas, métricas globais podem ser enganosas. É fundamental analisar o desempenho específico na classe positiva (pacientes com asma). A Figura 8 detalha a Precisão, Recall e F1-Score separadamente para cada classe.

O resultado mais impactante reside na diferença de **Recall (Sensibilidade)** para a classe 1 (barras laranjas).

- O **MLP Padrão** obteve um Recall de apenas 0.42. Isso significa que ele falhou em identificar 58% dos asmáticos presentes no teste.
- A **Decision Tree** teve desempenho similarmente baixo em Recall (0.30), priorizando a precisão da classe majoritária.

- O **KerasMLP**, graças à sua arquitetura otimizada e função de perda ajustada, alcançou um Recall de **0.88**. Ele foi capaz de recuperar a grande maioria dos casos reais, o que é a característica mais desejável em uma ferramenta de triagem.

O F1-Score da classe asmática no KerasMLP (0.81) foi substancialmente superior aos demais (0.47 no KNN e 0.49 na Random Forest), confirmando sua robustez no equilíbrio entre precisão e revocação.

**4.4.1 Desempenho na Classe Majoritária (Não Asmáticos).** Em saúde pública, a especificidade é crucial para evitar alarmes falsos e sobrecarga do sistema. A Figura 9 detalha o comportamento dos modelos para a classe 0 (Não Asmáticos).

O **MLP (Scikit-Learn)** apresentou a maior taxa de acerto para não asmáticos (0.96), comportando-se de maneira conservadora. Em contrapartida, a **Decision Tree** apresentou a pior taxa (0.41), classificando erroneamente uma grande proporção de saudáveis como doentes (falsos positivos de 0.59). O **KerasMLP** manteve um equilíbrio aceitável, com 0.90 de acerto nos não asmáticos, sacrificando uma pequena parcela de especificidade em troca do alto ganho de sensibilidade observado anteriormente.

#### 4.5 Matrizes de Confusão: A Realidade Operacional


As matrizes de confusão (Figura 10) traduzem as porcentagens em números absolutos de pacientes, permitindo avaliar o impacto clínico.

- **Decision Tree:** Gerou 471 Falsos Positivos. Em um cenário real, isso significaria encaminhar 471 pessoas saudáveis desnecessariamente para exames caros, sobrecarregando o sistema.
- **MLP (Scikit-Learn):** Apresentou comportamento "tímido". Gerou poucos falsos positivos (33), mas deixou passar 154 doentes (Falsos Negativos). O custo do subdiagnóstico aqui é alto, pois esses pacientes ficariam sem tratamento.
- **KerasMLP:** Apresentou o melhor balanço operacional. Identificou 232 Verdadeiros Positivos (quase o dobro do MLP padrão) e reduziu os Falsos Negativos para apenas 33. Embora tenha gerado 79 Falsos Positivos, esse número é aceitável em triagem primária, onde a prioridade é não perder casos positivos.

#### 4.6 Interpretabilidade: Extração de Regras da Árvore


Apesar da superioridade numérica das redes neurais, elas funcionam como "caixas-pretas". Para entender *o que* os dados dizem sobre a asma, recorreremos à Árvore de Decisão podada (Profundidade 3), apresentada na Figura 11.

A estrutura hierárquica revela uma "narrativa" dos dados: 1. **O Divisor Primário (Raiz):** A variável P034 (Prática de exercícios nos últimos 3 meses) é o nó raiz. Isso sugere que, na amostra da PNS 2019, o sedentarismo é o fator que melhor inicia a separação dos grupos. 2. **O Papel da Dieta:** No ramo dos indivíduos que *não* praticam exercícios (Esquerda), o próximo critério de divisão é o ULTRA\_SCORE. Se o indivíduo é sedentário e possui alto consumo de ultraprocessados, a probabilidade de pertencer à classe



PNS 2019 - Asma

**Figura 8: Detalhamento de métricas por classe. Note a superioridade expressiva do KerasMLP (coluna central) nas métricas da Classe 1 (Laranja), especialmente no Recall (0.88) e F1-Score (0.81).**



PNS 2019 - Asma

**Figura 9: Proporção de acertos (TN) e erros (FP) na classe de Não Asmáticos. O MLP padrão prioriza especificidade, enquanto a Decision Tree gera excesso de falsos positivos.**

de risco aumenta. 3. **Refinamento Contextual:** Nos níveis subsequentes, variáveis como V0026 (Urbano/Rural) e A003010 (Material do telhado) aparecem para refinar a classificação, indicando que, após definidos os hábitos, o contexto socioeconômico e ambiental modula o risco residual.

#### 4.7 Visualização do Espaço de Características (t-SNE)

Para compreender a dificuldade dos modelos lineares, aplicou-se a técnica t-SNE (t-Distributed Stochastic Neighbor Embedding) no

conjunto de treino balanceado. A projeção 2D (Figura 12) mostra a distribuição topológica das amostras.

Observa-se que não há uma separação linear clara (um "vão" vazio) entre as classes 0 e 1. Os pontos estão entrelaçados em regiões complexas. Isso explica por que modelos mais simples (como a Árvore rasa ou regressões lineares) têm dificuldade em atingir alta precisão sem gerar muitos falsos positivos. A sobreposição exige fronteiras de decisão curvas e multidimensionais, algo que apenas as camadas ocultas das redes neurais conseguem construir com eficácia.

## 5 Discussão

### 5.1 Interpretação Epidemiológica dos Achados

Os resultados obtidos corroboram a hipótese da determinação social e comportamental da asma. A proeminência da atividade física (P034) como nó raiz na árvore de decisão alinha-se com a literatura que descreve o efeito protetor do exercício na função pulmonar e na regulação inflamatória. O sedentarismo não apenas reduz a capacidade cardiorrespiratória, mas também está frequentemente associado à obesidade, um estado pró-inflamatório conhecido por complicar o controle da asma.

A associação com alimentos ultraprocessados (ULTRA\_SCORE) observada no segundo nível da árvore reforça as diretrizes do Guia Alimentar para a População Brasileira. A presença de aditivos (conservantes, corantes) e o perfil nutricional inadequado desses alimentos podem contribuir para a inflamação sistêmica. O modelo sugere que a dieta atua como um "segundo golpe": em indivíduos já sedentários, a má alimentação catalisa o risco.




Figura 10: Matrizes de confusão dos classificadores. Comparando os quadrantes inferiores (Real 1), o KerasMLP maximiza os acertos (232) enquanto minimiza a perda de pacientes (33).





Figura 11: Visualização da Árvore de Decisão. O fluxo de regras prioriza a inatividade física (P034) e o consumo de ultraprocessados (ULTRA\_SCORE) para definir os nós de maior pureza.





**Figura 12: Projeção t-SNE dos dados balanceados. A sobreposição das classes (roxo e amarelo) ilustra a complexidade não linear do problema.**

As variáveis de habitação (A003010, A004010) e a presença de animais (A02306) atuam como marcadores indiretos de exposição a alérgenos (ácaros, fungos, pelos) e status socioeconômico. A capacidade do modelo de integrar esses fatores ambientais com os comportamentais demonstra a vantagem da abordagem multivariada sobre análises isoladas.

## 5.2 Implicações para o Uso de IA no SUS

A análise comparativa dos modelos traz lições valiosas para a implementação de Inteligência Artificial no sistema público de saúde. O desempenho superior do **KerasMLP** em sensibilidade (Recall) sugere que redes neurais profundas são mais adequadas para tarefas de *screening* (triagem), onde o objetivo é não deixar passar nenhum caso potencial. Um modelo com alto Recall poderia ser embarcado nos sistemas de Prontuário Eletrônico da Atenção Primária (e-SUS), alertando o médico da família para investigar ativamente a asma em pacientes com o perfil de risco identificado (sedentário, alta ingestão de processados, condições de moradia específicas), mesmo que a queixa principal da consulta seja outra.

Por outro lado, a **Decision Tree**, embora menos precisa, oferece valor educativo. Sua estrutura visual pode ser transformada em cartazes ou materiais educativos simples: "Você pratica esportes? Como é sua alimentação?". Isso empodera os Agentes Comunitários de Saúde com uma lógica de risco compreensível, sem depender de "caixas-pretas" computacionais.

## 5.3 Limitações do Estudo

É necessário reconhecer as limitações inerentes ao desenho do estudo. Sendo a PNS um inquérito transversal, não é possível estabelecer causalidade temporal (ex: a pessoa tem asma porque é sedentária, ou tornou-se sedentária porque a asma dificulta o exercício?). O viés de causalidade reversa é real. Além disso, o desfecho é autorreferido ("um médico já disse..."), o que depende do acesso prévio ao diagnóstico, podendo subestimar a prevalência em populações muito vulneráveis que nunca consultaram um médico.

## 6 Conclusão e Trabalhos Futuros

Este estudo utilizou dados da PNS 2019 para lançar luz sobre os determinantes da asma no Brasil sob a ótica da Ciência de Dados. Conclui-se que a asma não se distribui aleatoriamente; ela segue padrões associados ao estilo de vida moderno — notadamente a inatividade física e o consumo de ultraprocessados — e às condições de moradia.

Do ponto de vista técnico, demonstramos que a escolha da arquitetura de Machine Learning é crítica. Enquanto modelos clássicos falharam em capturar a classe minoritária adequadamente, a arquitetura de Redes Neurais profundas (KerasMLP) provou-se robusta, oferecendo sensibilidade elevada (Recall 0.88) essencial para aplicações de saúde pública.

Para trabalhos futuros, sugere-se a aplicação de técnicas de *Explainable AI* (XAI) mais avançadas, como SHAP (SHapley Additive exPlanations), para interpretar a rede neural KerasMLP, unindo a alta performance da rede com a explicabilidade da árvore. Além disso, análises longitudinais com futuras edições da PNS poderão ajudar a elucidar a direção causal das associações aqui encontradas.

As evidências suportam a necessidade de políticas integradas: o combate à asma passa necessariamente pelo incentivo à atividade física e pela regulação de alimentos ultraprocessados, ações que transcendem o consultório médico e alcançam o planejamento urbano e a regulação sanitária.

## Referências

- [1] IBGE. 2020. *Pesquisa Nacional de Saúde 2019: percepção do estado de saúde, estilos de vida, doenças crônicas e saúde bucal*. Rio de Janeiro: IBGE.
- [2] Monteiro, C. A. et al. 2019. Ultra-processed foods: what they are and how to identify them. *Public Health Nutrition*, 22(5), 936–941.
- [3] Menezes, A. M. B. et al. 2015. Prevalence of asthma in adults in Brazil: results from the National Health Survey 2013. *Jornal Brasileiro de Pneumologia*, 41(5), 398–404.
- [4] Baraldi, E. et al. 2020. Interplay between nutrition and asthma. *Nutrients*, 12(6), 1735.
- [5] Ramos, D.; Martins, D.; Castro, M. 2021. Prevalência de asma nas regiões do Brasil: revisão sistemática. *Physis*, 31(2), e310220.
- [6] Estandislau, N. R. A. et al. 2021. Association between asthma and sleep hours in Brazilian adolescents: ERICA. *Jornal de Pediatria*, 97(4), 396–401.
- [7] Kaplan, A. et al. 2021. Artificial intelligence/machine learning in respiratory medicine and potential role in asthma and COPD diagnosis. *JACI: In Practice*, 9(6), 2255–2261.
- [8] LeCun, Y.; Bengio, Y.; Hinton, G. 2015. Deep learning. *Nature*, 521(7553), 436–444.
- [9] Finkelstein, J.; Jeong, I. C. 2017. Machine learning approaches to personalize early prediction of asthma exacerbations. *Annals of the New York Academy of Sciences*, 1387(1), 153–165.
- [10] Lual, N.; Awoke, T. 2021. Factors associated with suboptimal asthma control among adults. *Journal of Asthma and Allergy*, 14, 1033–1042.
- [11] Global Initiative for Asthma (GINA). 2020. *Global Strategy for Asthma Management and Prevention*. GINA Report.
- [12] World Health Organization. 2021. *Noncommunicable diseases: Childhood overweight and obesity*. WHO.
- [13] Pedregosa, F. et al. 2011. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.



[14] Chollet, F. et al. 2015. *Keras*. GitHub. <https://github.com/fchollet/keras>.

[15] Meltzer, L. J. et al. 2019. The role of sleep in asthma outcomes in adolescents. *Journal of Asthma*, 56(9), 957–965.