

PNS 2019

Anderson Babetto

Aprendizado de máquina

PUC Minas Lódes

Minas Gerais/Brasil

andersonbabetto13@outlook.com

1. Descrição do Problema

Este estudo emprega Mineração de Dados para realizar uma Análise Exploratória e de Classificação sobre a prevalência de Artrite na população brasileira, com foco específico na subpopulação entre 40 e 60 anos, utilizando os microdados da Pesquisa Nacional de Saúde (PNS) 2019. O principal objetivo de pesquisa é desenvolver e validar um modelo de classificação que possa não apenas prever, mas também identificar os principais fatores preditivos (entre variáveis socioeconômicas, demográficas, de estilo de vida, de histórico de saúde e alimentares) que são estatisticamente relevantes para a distinção entre indivíduos diagnosticados com Artrite e o grupo de controle.

2. Descrição da Base de Dados

A base de dados em estudo constitui um subconjunto derivado dos microdados da Pesquisa Nacional de Saúde (PNS) 2019. O *dataset* original da PNS 2019 é uma fonte robusta de saúde pública, totalizando 279.382 registros e aproximadamente 150 atributos. Para os propósitos desta análise, o *dataset* foi filtrado para incluir apenas a subpopulação entre 40 e 60 anos e indivíduos com informação de diagnóstico de Artrite. A partir do universo de variáveis disponíveis, uma seleção focada de cerca de 30 atributos foi realizada. Essa seleção compreende variáveis consideradas relevantes para o problema de classificação.




Figura 1: Diagrama Entidade-Relacionamento para o domínio de Artrite

3. Pipeline de Mineração e Pré-Processamento

Para transformar os dados brutos da Pesquisa Nacional de Saúde (PNS) 2019 em um conjunto de dados pronto para a modelagem preditiva da Artrite, um pipeline rigoroso de pré-processamento foi executado em ordem cronológica, conforme detalhado nas subseções a seguir.

3.1. Filtros Iniciais e Definição da Coorte

A *dataset* inicial da PNS foi submetido a filtros iniciais para definir a coorte de interesse. O foco foi estabelecido em indivíduos na faixa etária de 40 a 60 anos com dados disponíveis sobre o diagnóstico de Artrite.




Figura 2: Frequência acumulada da Idade do indivíduo

Após os filtros iniciais e a seleção de *features*, o subconjunto de dados para análise continha aproximadamente 24.000 registros antes da aplicação das técnicas de balanceamento.

3.2. Engenharia e Limpeza de Features Numéricas

A engenharia e limpeza das *features* foram cruciais para aprimorar o poder preditivo do modelo:

Derivação de Atributos: O Índice de Massa Corporal (IMC) foi derivado das variáveis de Peso e Altura. Uma métrica para a frequência de exercícios físicos foi construída pela combinação das variáveis P034 e P035, entre outras combinações de frequência.

Limpeza de Dados: Códigos de erro e dados corrompidos foram tratados e convertidos em valores ausentes (*NaN*).

3.3. Renomeação de Variáveis

Para melhorar a interpretabilidade dos dados e dos modelos, as colunas foram renomeadas de seus códigos originais (ex: C006, P006) para nomes legíveis (ex: SEXO, FEIJAO).

3.4. Remoção de Outliers

Código: <https://github.com/AnderBabetto/Projeto-Artrite/blob/main/outliers.ipynb>

A remoção de *outliers* foi realizada nas *features* numéricas utilizando a técnica do Z-Score (desvio-padrão). Crucialmente, esta técnica foi aplicada exclusivamente ao conjunto de Treinamento após a divisão inicial da base. Foram removidos os registros cujos valores excedem um limiar de 3 desvios-padrão em relação à média de sua respectiva variável, minimizando o impacto de valores extremos no aprendizado do modelo sem introduzir *data leakage* do conjunto de Teste.




Figura 3: Visualização da remoção de Outliers do conjunto de Treino.

3.5 Imputação de Valores Ausentes

KNNImputer: <https://github.com/AnderBabetto/Projeto-Artrite/blob/main/imputaçãoKNN.ipynb>

MissForest: <https://github.com/AnderBabetto/Projeto-Artrite/blob/main/imputaçãoMF.ipynb>

Métricas: <https://github.com/AnderBabetto/Projeto-Artrite/blob/main/TesteMetricasImputers.ipynb>

Para o tratamento dos valores ausentes residuais após a limpeza e engenharia, foram comparados os algoritmos MissForest e KNNImputer.

Validação: A eficácia dos métodos foi validada usando o classificador KNN ($K = 3, 5, 7, 9, 11$)

Decisão: Os resultados indicaram a consistência e o desempenho superior do KNNImputer nas métricas avaliadas. Portanto, a base imputada com o KNNImputer foi adotada para as etapas subsequentes.




Figura 4: Desempenho da classificação (Curva ROC) no conjunto de treino para os dados imputados por KNNImputer e MissForest.

3.6. Pipeline de Preparação para Modelagem

Esta etapa final seguiu rigorosamente as melhores práticas para evitar o vazamento de dados (*data leakage*) e preparar a base imputada para o classificador.

a) Divisão Treino-Teste (Train-Test Split)

O *dataset* foi dividido em conjuntos de Treino (70%) e Teste (30%). O conjunto de teste foi segregado para ser utilizado apenas na avaliação final, representando o desempenho no "mundo real". O parâmetro *stratify=y* foi aplicado para manter a proporção original de classes desbalanceadas em ambas as divisões.

b) Visualização da Estrutura dos Dados (t-SNE)

Após a divisão Treino-Teste e antes das transformações de *encoding*, *scaling* e balanceamento, aplicou-se a técnica de t-Distributed Stochastic Neighbor Embedding (t-SNE) para visualizar a estrutura intrínseca dos dados em duas dimensões. Este gráfico foi gerado a partir do conjunto de Treino para observar a separabilidade das classes (0 = indivíduos saudáveis vs. 1 = indivíduos com Artrite vs.) no espaço de *features*.




Figura 5: Visualização t-SNE do conjunto de Treino, destacando a distribuição das classes.

c) Pré-processamento

O pré-processamento foi "aprendido" (*fit*) no conjunto de treino e apenas "aplicado" (*transform*) no conjunto de teste:

Discretização/Binarização: As variáveis numéricas (contínuas) foram submetidas à discretização (binning), transformando-as em variáveis categóricas ou ordinais em faixas. Essa técnica foi aplicada para converter os valores numéricos em intervalos definidos, facilitando a interpretação e manipulação pelo classificador.

Codificação (Encoding): Variáveis ordinais (que possuem uma hierarquia ou ordem intrínseca, ex: nível de escolaridade) foram convertidas usando Label Encoding. Variáveis nominais (que não possuem ordem, ex: sexo) foram transformadas em colunas binárias via One-Hot Encoding (OHE).

3.7. Balanceamento dos dados

Código: <https://github.com/AnderBabetto/Projeto-Artrite/blob/main/TesteBalanceamentos.ipynb>

A base de dados de Treino, após *encoding* e *scaling*, apresentava um desbalanceamento significativo. Para resolver essa assimetria sem perder informações críticas da classe majoritária nem introduzir excessivo ruído sintético, foi implementada uma estratégia híbrida em duas etapas:

Undersampling Seletivo (RUS): Inicialmente, o Random Under-Sampler (RUS) foi aplicado com um ratio de 0.1 (ou seja, reduzindo a classe majoritária até que ela representasse 10% do seu tamanho original em relação à minoritária). Esta etapa teve como objetivo reduzir apenas parcialmente a classe majoritária, preservando a maior parte de sua informação e preparando o *dataset* para a próxima fase.

Oversampling (SMOTE): Em seguida, a técnica SMOTE (Synthetic Minority Oversampling Technique) foi aplicada. O SMOTE gerou novos registros sintéticos da classe minoritária até que ela atingisse o tamanho da classe majoritária após a primeira etapa de RUS, resultando em uma distribuição de classes perfeitamente balanceada (50%/50%).

Esta combinação visa otimizar a performance do modelo, utilizando o *Undersampling* para mitigar o viés e o *Oversampling* para garantir que o modelo de classificação aprenda padrões suficientes da classe minoritária (Artrite).

4. Conjunto de Dados Final para Modelagem

Ao final do pipeline, foram gerados os conjuntos de dados para modelagem:

Conjunto de Treino: *Features* codificadas, padronizadas e balanceadas; alvo balanceado.

Conjunto de Teste: *Features* codificadas e padronizadas (usando os parâmetros aprendidos no Treino); alvo no estado original desbalanceado.



Figura 6: Imagem do Pipeline

5. Modelos Finais de Classificação e Otimização de Hiperparâmetros

Para a avaliação do desempenho do *dataset final*, foram selecionados três algoritmos distintos: Bernoulli Naive Bayes (NB), Árvore de Decisão (DT) e Extra Tree (ET). Cada modelo foi submetido a um rigoroso processo de Otimização Bayesiana de Hiperparâmetros utilizando o BayesSearchCV (da biblioteca skopt). Este método é mais eficiente que a Busca em Grade tradicional, explorando o espaço de hiperparâmetros de forma inteligente para encontrar a combinação ótima em menos iterações.

No entanto, em uma etapa posterior, visando refinar ainda mais os resultados e explorar a sinergia da seleção de features, o método Ant Colony Optimization (ACO), inspirado na "colônia de formigas", foi crucialmente empregado para definir a combinação final e mais robusta de features para os modelos.

A métrica de otimização primária utilizada em todos os modelos foi o F1-Score (da classe 1), visando o melhor equilíbrio entre *Precision* (Precisão) e *Recall* (Sensibilidade) no contexto do problema de classificação desbalanceado.

5.1. Ant Colony Optimization (ACO) para Seleção de Features

O Ant Colony Optimization (ACO) é uma meta-heurística de otimização combinatória que simula o comportamento coletivo e inteligente de formigas na busca por caminhos ótimos. No Projeto Artrite, o ACO foi aplicado para selecionar um subconjunto ideal de features. O algoritmo foi utilizado para navegar pelo vasto espaço de possíveis variáveis, atribuindo um "feromônio" virtualmente às features mais promissoras – aquelas que, em diferentes combinações, resultavam nos melhores F1-Scores. Este processo iterativo permitiu identificar o conjunto de variáveis que maximizou o desempenho dos modelos finais, otimizando a capacidade preditiva e a eficiência computacional.

5.2. Espaços de Busca

Os parâmetros e intervalos testados para cada modelo são:

Árvore de Decisão (DT):

- max_depth: Entre 3 e 15
- min_samples_split: Entre 2 e 20
- min_samples_leaf: Entre 1 e 10
- max_features: None, 'sqrt', 'log2', 0.2, 0.4, 0.6, 0.8
- criterion: gini, entropy

Extra Tree (ET):

- n_estimator: Entre 20 e 150
- max_depth: Entre 3 e 15
- min_samples_split: Entre 2 e 20
- min_samples_leaf: Entre 1 e 10
- max_features: None, 'sqrt', 'log2', 0.2, 0.4, 0.6, 0.8
- criterion: gini, entropy, log_loss
- bootstrap: True, False

Bernoulli Naive Bayes (NB):

- Alpha: Entre 1e-5 a 1000.0

5.3. Melhores Hiperparâmetros

Após a execução da Otimização Bayesiana (via BayesSearchCV), os seguintes melhores hiperparâmetros foram identificados para cada modelo:

Hiperparâmetro	Naive Bayes
Alpha	0.01909

Hiperparâmetro	Decision Tree	Extra Tree
Profundidade máxima (max_depth)	4	10
Mín. Amostras (Divisão) (min_samples_split)	10	20
Mín. Amostras (Folha) (min_samples_leaf)	2	1
Recursos Máximos (max_features)	0.8	None
Crítério de Decisão (criterion)	gini	gini
Qtd. de Árvores (n_estimator)	N/A	120

6. Avaliações Finais dos Modelos

Código: <https://github.com/AnderBabetto/ProjetoArtrite/blob/main/TesteFinalACO.ipynb>

A avaliação final dos modelos otimizados (best_estimator_do BayesSearchCV) foi realizada no conjunto de teste (X_test_final), o que simulou a performance em dados de produção.

6.1. Análise das Métricas

As métricas finais de desempenho, mensuradas no conjunto de teste, foram as seguintes:

Naive Bayes:

Classe	Precision	Recall	F1-Score
0 (Tem Artrite)	0.20	0.66	0.31
1 (Sem Artrite)	0.96	0.76	0.85

Extra Tree:

Classe	Precision	Recall	F1-Score
0 (Tem Artrite)	0.23	0.56	0.33
1 (Sem Artrite)	0.95	0.83	0.89

Decision Tree:

Classe	Precision	Recall	F1-Score
0 (Tem Artrite)	0.24	0.54	0.33
1 (Sem Artrite)	0.95	0.84	0.89

6.2. Análise das Métricas Avançadas

A fase de análise foi aprofundada, introduzindo métricas que avaliam a qualidade e a confiabilidade preditiva interna de cada modelo: o pHi e o HIT. O pHi (Índice de Confiabilidade de Previsão) representa a média das probabilidades de previsão somente nos casos em que o modelo acertou a classificação. Paralelamente, a métrica HIT foi utilizada para focar a avaliação na performance do modelo entre os seus acertos, medindo a proporção dos Verdadeiros Positivos (VP) em relação ao total de acertos de ambas as classes (VP + Verdadeiros Negativos).

Métricas Médias	Naive Bayes	Extra Tree	Decision Tree
pHi	0.87	0.84	0.84
Hit	0.93	0.94	0.95
F1-Score	0.58	0.61	0.61

6.3. Matrizes de Confusão dos Modelos Finais




Figura 11: Matriz de Confusão do Naive Bayes (NB)




Figura 12: Matriz de Confusão do Extra Tree (ET)




Figura 13: Matriz de Confusão da Árvore de Decisão (DT)

As matrizes de confusão fornecem uma visão detalhada do desempenho em termos de acertos e erros (Falso Positivo e Falso Negativo) no conjunto de Teste não balanceado.

7. Interpretação das Regras

Código: [Projeto-Artrite/AnaliseRegrasNB at main · AnderBabetto/Projeto-Artrite · GitHub](#)

Ambos os modelos de classificação, Naive Bayes (NB) e Árvore de Decisão (DT), convergem ao identificar que a presença de OUTRAS DOENÇAS é o fator mais crítico e dominante no risco de desenvolver Artrite, apresentando o Log-Odds mais alto no NB (1.489) e servindo como o segundo critério de divisão mais importante na DT, logo após a raiz. Além disso, a IDADE e o SEXO são variáveis preditoras centrais. O papel destas variáveis demográficas é crucial para identificar o subgrupo de maior risco: o modelo NB indica que o SEXO Feminino (código 2) atua como um forte fator de proteção (Log-Odds negativo de -0.493), enquanto o SEXO Masculino (código 1) está associado a uma maior chance da doença. A DT corrobora isso ao usar a regra $\text{SEXO} \geq 1.05$, separando o caminho de maior risco (Homens).

Quanto à IDADE, os modelos apresentam o achado contraintuitivo e consistente de que o aumento da idade categórica (indo de 40-44 para 55-60) é um fator de proteção (Log-Odds de -0.265), sendo o caminho de alto risco definido, em grande parte, pelas faixas etárias mais jovens (40 a 49 anos), que são o primeiro e crucial ponto de ramificação da árvore. No que tange aos fatores comportamentais e dietéticos, o modelo Naive Bayes indica que ter DEPRESSÃO e consumir REFRIGERANTE são fatores de risco mais leves, elevando levemente a probabilidade da doença. Em contrapartida, o consumo de FRUTA e FEIJÃO está associado a uma leve redução na probabilidade de Artrite.

No geral, as descobertas enfatizam que as condições clínicas preexistentes (OUTRAS DOENÇAS e DEPRESSÃO) exercem um impacto exponencialmente maior sobre o risco do que as variáveis de estilo de vida analisadas. A integração desses resultados aponta para uma regra de alto risco para Artrite: IF o indivíduo possui OUTRAS DOENÇAS AND é do SEXO Masculino AND pertence às faixas de IDADE mais jovens (40-49 anos). Por outro lado, a maior proteção contra a doença está associada à ausência de OUTRAS DOENÇAS e ao SEXO Feminino, especialmente nas faixas etárias mais avançadas (50-60 anos).

8. Conclusão

A análise comparativa dos classificadores otimizados (NB, ET e DT) revelou que o Bernoulli Naive Bayes (NB) após otimização via BayesSearchCV e SelectKBest (ACO), foi o modelo selecionado como o modelo final para este projeto.

A escolha foi baseada na prioridade da métrica Recall (Sensibilidade), que mede a capacidade do modelo de identificar corretamente os casos positivos (indivíduos com Artrite).

O modelo Bernoulli Naive Bayes obteve o melhor Recall geral entre todos os classificadores testados, indicando uma taxa de Falsos Negativos (FN) bem equilibrada.

Em um contexto de triagem e diagnóstico em saúde pública, a prioridade máxima é evitar que pacientes doentes sejam incorretamente classificados como saudáveis, pois o custo do tratamento tardio é clinicamente mais alto do que o custo de um Falso Positivo (FP).

Adicionalmente, o Naive Bayes apresentou a melhor média de pHi (Confiabilidade) e a segunda melhor média de HIT, atestando sua robusta capacidade de discriminação e separação de classes em diferentes limiares.

Apesar de o Decision Tree e o Extra Tree terem alcançado uma *Precision* maior, o Recall superior do NB garante a máxima cobertura da população com Artrite, tornando-o a escolha mais adequada para o objetivo de identificação de casos na fase de triagem.

9. Referências

- [1] FRONTIERS IN NUTRITION. *Machine learning-driven insights into lipid metabolism and inflammatory pathways in knee osteoarthritis*. Frontiers in Nutrition, v. 12, 2025. DOI: 10.3389/fnut.2025.1552047. Disponível em: <https://www.frontiersin.org/journals/nutrition/article/s10.3389/fnut.2025.1552047/full>.
- [2] MULTIMEDIA TOOLS AND APPLICATIONS. *Prediction of hidden patterns in rheumatoid arthritis patients records using data mining*. Multimedia Tools and Applications, v. 81, p. 27655-27673, 2022. DOI: 10.1007/s11042-022-13331-y. Disponível em: <https://dl.acm.org/doi/10.1007/s11042-022-13331-y>.

- [3] FRONTIERS IN NUTRITION. *Diet affects inflammatory arthritis: a Mendelian randomization study of 30 dietary patterns causally associated with inflammatory arthritis*. Frontiers in Nutrition, v. 11, 2024. DOI: 10.3389/fnut.2024.1426125. Disponível em: <https://www.frontiersin.org/articles/10.3389/fnut.2024.1426125/full>.
- [4] REVISTA DA ASSOCIAÇÃO MÉDICA BRASILEIRA. *Avaliações dietética e antropométrica em artrite reumatoide juvenil*. Revista da Associação Médica Brasileira, SciELO, 2014. Disponível em: <https://www.scielo.br/j/ramb>.
- [5] JOURNAL OF SCIENTIFIC INNOVATION IN MEDICINE. *Innovative Machine Learning Approach for Distinguishing Rheumatoid Arthritis and Osteoarthritis: Integrating Shapely Additive Explanations and Dendrograms*. Journal of Scientific Innovation in Medicine, v. 7, n. 1, p. 181, 2024. DOI: 10.29024/jsim.181. Disponível em: <https://journalofscientificinnovationinmedicine.org/articles/10.29024/jsim.181>.
- [6] AMERICAN JOURNAL OF CLINICAL NUTRITION. *Machine learning with ingredient-level food trees reveals contributors to systemic inflammation among adults in the National Health and Nutrition Examination Survey, 2001–2010 and 2015–2018*. American Journal of Clinical Nutrition, 2024. PMID: 40446924. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/40446924/>.
- [7] REVISTA BRASILEIRA DE REUMATOLOGIA. *Perfil nutricional do paciente com artrite reumatoide*. Revista Brasileira de Reumatologia, SciELO, 2014. Disponível em: <https://www.scielo.br/j/rbr>.
- [8] NUTRITION & METABOLISM. *The relationship between dietary patterns and rheumatoid arthritis: case-control*. Nutrition & Metabolism, v. 17, n. 26, 2020. DOI: 10.1186/s12986-020-00458-7. Disponível em: <https://nutritionandmetabolism.biomedcentral.com/articles/10.1186/s12986-020-00458-7>.
- [9] NUTRITION JOURNAL. *Anti-inflammatory Diet In Rheumatoid Arthritis (ADIRA): protocolo de ECR cruzado*. Nutrition Journal, v. 17, n. 44, 2018. DOI: 10.1186/s12937-018-0331-2. Disponível em: <https://nutritionj.biomedcentral.com/articles/10.1186/s12937-018-0331-2>.
- [10] REVISTA FOCO. *Artrite reumatoide: os benefícios de uma alimentação anti-inflamatória*. Revista Foco, v. 17, n. 10, p. 01-13, 2024. DOI: 10.54751/revistafoco.v17n10-124. Disponível em: <https://revistafoco.emnuvens.com.br/foco/article/view/6610>.
- [11] Fix, E. e Hodges, J. L. (1951). Discriminatory Analysis. Nonparametric Discrimination: Consistency Properties. *US Air Force School of Aviation Medicine, Randolph Field, TX*, Report No. 4.
- [12] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. DOI: 10.1023/A:1010933404324.
- [13] Quinlan, J. R. (1993). C4.5: Programs for Machine Learning. *Morgan Kaufmann Publishers*.
- [14] Chawla, N. V. et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357. DOI: 10.1613/jair.953.
- [15] Mockus, J. (1978). The application of Bayesian methods for seeking the extremum. *Journal of Global Optimization* (Originalmente em Russo).

10. Dicionário dos Dados

O Dicionário dos Dados é apresentado nesta seção, contendo a descrição completa das *features* utilizadas no modelo.

Variável	Descrição da variável	Código/Valor	Descrição da resposta
TEM_ARTRITE	O individuo tem diagnóstico de Artrite?	0	Sim
		1	Não
SEXO	Sexo	2	Mulher
		2	Mulher
IDADE	Idade do morador na data de referência	0	Entre 40 e 44 anos
		1	Entre 45 e 49 anos
		2	Entre 50 e 54 anos
		3	Entre 55 e 60 anos
BISCOITO	Em quantos dias da semana o(a) Sr(a) costuma comer biscoitos/guloseimas?	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes
FAIXA_DE_RENDA	Valor total habitualmente recebido	99999999	valor em reais
FEIJAO	Em quantos dias da semana o(a) Sr(a) costuma comer feijão?	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes
VEGETAIS	Em quantos dias da semana, o(a) Sr(a) costuma comer pelo menos um tipo de verdura ou legume (sem contar batata, mandioca, cará ou inhame) como alface, tomate, couve, cenoura, chuchu, berinjela, abobrinha?	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes
CARNE	Em quantos dias da semana o(a) Sr(a) costuma comer carne vermelha (boi, porco, cabrito, bode, ovelha etc.)?	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes
PEIXE	Em quantos dias da semana o(a) Sr(a) costuma comer peixe?	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes
SUCO	Em quantos dias da semana o(a) Sr(a) costuma tomar suco de caixinha/lata ou refresco em pó ?	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes

ALCOOL	Em quantos dias da semana o(a) Sr(a) costuma ingerir bebidas alcóolicas?	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes
SUCO_NATURAL	Em quantos dias da semana o(a) Sr(a) costuma tomar suco de fruta natural (incluída a polpa de fruta congelada)?	1 a 7	Dias
		0	Nunca ou menos de uma vez por semana.
		9	Ignorado
			Não aplicável
FRUTA	Em quantos dias da semana o(a) Sr(a) costuma comer frutas?	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes
REFRIGERANTE	Em quantos dias da semana o(a) Sr(a) costuma tomar refrigerante?	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes
LEITE	Em quantos dias da semana o(a) Sr(a) costuma tomar leite? (de origem animal: vaca, cabra, búfala etc.)	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes
TIPO_LEITE	Que tipo de leite o(a) Sr(a) costuma tomar?	1	Desnatado ou semidesnatado.
		2	Integral
		3	Os dois tipos
		9	Ignorado
			Não aplicável
FAST_FOOD	Em quantos dias da semana o(a) Sr(a) costuma substituir a refeição do almoço por lanches rápidos como sanduíches, salgados, pizza, cachorro quente, etc?	0	0 dias
		1	1 ou 2 vezes
		2	Entre 3 a 5 vezes
		3	6 ou 7 vezes
IMC	Índice de massa corporal	0	Menor que 18.5
		1	Menor que 25
		2	Menor que 30
		3	Maior que 30
TRABALHA	Condição de ocupação	0	Não trabalha
		1	Trabalha